



Bachelor Informatik/Wirtschaftsinformatik

Integrationsprojekt Kryptographie Teil 2

Spezifikationsdokument

Hannover, 9. Juni 2026

Sommerquartal 2026

Nina Neumann, Johanna Amini, Amirreza Ahmadi Darani, Xuan-Loc Tran, Franz Müller, Tammo Lütten,
Jannes Breuer, Bjarne Möller, Darko Marjanovic, Oliver Knöbl, Rafael Ulmer

Anmerkung

Die vorliegende Arbeit wurde im Rahmen eines wissenschaftlichen Projekts an der Fachhochschule für die Wirtschaft (FHDW) Hannover erstellt. Alle in dieser Arbeit verwendeten Informationen, Daten und Ergebnisse sind ausschließlich für akademische Zwecke bestimmt. Die Autoren übernehmen keine Verantwortung für die Richtigkeit, Vollständigkeit oder Aktualität der in dieser Arbeit enthaltenen Informationen. Jegliche Nutzung der Inhalte dieser Arbeit erfolgt auf eigenes Risiko.

Erklärung der Selbstständigkeit

Hiermit versichern wir, dass wir das vorliegende Spezifikationsdokument selbständig verfasst und keine anderen als die angegebenen Quellen verwendet haben. Alle Textstellen und andere Inhalte wie Bilder, Quellcode oder Daten, die wörtlich oder sinngemäß aus anderen Quellen entnommen sind, haben wir eindeutig mit korrekten Quellenangaben versehen. Über Zitierrichtlinien sind wir schriftlich informiert worden. Diese Arbeit wurde bisher in gleicher oder ähnlicher Form, auch nicht in Teilen, keiner anderen Prüfungsbehörde vorgelegt.

Falls wir während der Erstellung dieser Arbeit generative KI oder andere KI-gestützte Technologien verwendet haben, die über grundlegende Werkzeuge für Übersetzungen und zur Überprüfung von Grammatik oder Rechtschreibung hinausgehen, erklären wir, nach der Nutzung dieser Tools den Inhalt unseres Spezifikationsdokuments überprüft und bearbeitet zu haben und übernehmen die volle Verantwortung für die diesbezüglichen Ausführungen. Eine Verwendung solcher Werkzeuge haben wir in unserer Arbeit dokumentiert (bspw. im Abschnitt „Struktur der Arbeit, Methodik“ oder durch Erläuterungen zur Nutzung im Anhang).

Inhaltsverzeichnis

1	Einleitung	3
2	Querschnittssektionen	4
2.1	Architektur-Übersicht	4
2.2	Gateway und Routing	5
2.3	Key Lifecycle	5
2.4	Serialisierung	5
2.5	Build, Deployment, Tests	5
3	Use-Cases	8
3.1	Encrypted-Key-Value-Store	8
3.2	Encrypted-Age-Verification	9
3.3	Encrypted-Voting-&-Polling	16
3.4	Sealed-Bid-Auction	30
3.5	Encrypted-Statistics-Service	35
3.6	Encrypted-Genomics	43
3.7	Encrypted-Image-Processing	52
3.8	Encrypted-Leaderboard	57
3.9	Encrypted-Program-Execution	58

1 Einleitung

2 Querschnittssektionen

2.1 Architektur-Übersicht

Gesamtarchitektur: Das System folgt einer Microservice-Architektur. Jeder Use Case (UC) wird als eigenständiger Service umgesetzt. Dadurch erhalten die einzelnen UCs getrennte Lebenszyklen, unabhängige Deployments und eine klare fachliche Verantwortlichkeit. Zusätzlich wird eine Isolation auf Prozessebene erreicht, sodass Fehler oder Abstürze eines Services keine Auswirkungen auf andere UCs haben.

Insbesondere im Kontext von Fully Homomorphic Encryption (FHE) ist diese Trennung vorteilhaft, da jeder Service seinen eigenen ServerKey im Arbeitsspeicher hält. In einer monolithischen Architektur würden sich die Speichieranforderungen aller UCs gegenseitig beeinflussen.

Die Services sind als Rust-Anwendungen implementiert und verwenden das Framework Axum für die Bereitstellung von HTTP-APIs. Wiederkehrende Funktionalitäten wie Health-Endpunkte, Prometheus-Metriken, Tracing und OpenAPI-Dokumentation werden über gemeinsame Shared Crates bereitgestellt.

Komponenten: Die Architektur besteht aus folgenden Hauptkomponenten:

Komponente	Technologie	Verantwortung
Frontend	Angular + TypeScript + TFHE.js	Benutzeroberfläche, clientseitige FHE-Operationen, Schlüsselgenerierung
API Gateway	Traefik	Routing eingehender Requests, TLS-Terminierung
UC-Service 1-9	Rust + Axum	Fachlogik des jeweiligen Use Cases
Redis	Redis	Speicherung von Session-Daten und Schlüsseln
Kubernetes (k3s)	Kubernetes	Orchestrierung und Skalierung
Observability Stack	Prometheus, Grafana, Tempo	Monitoring, Metriken und Tracing

FHE-Grenze: Folgende Komponenten verarbeiten FHE-spezifische Datentypen:

- Frontend (TFHE.js)
- UC-Services (Rust + tfhe-rs)
- Redis (gespeicherte Schlüsselmaterialien)

Folgende Komponenten kennen keine FHE-internen Datentypen:

- Traefik Gateway
- Kubernetes
- Observability-Komponenten

2.2 Gateway und Routing

Als API-Gateway wird Traefik eingesetzt. Traefik unterstützt die Kubernetes Gateway API und übernimmt das Routing eingehender HTTP-Anfragen auf die jeweiligen UC-Services.

Routing: Das Routing erfolgt pfadbasiert. Requests werden anhand ihres URL-Pfades an den zuständigen Microservice weitergeleitet.

Rate Limiting: Traefik bietet technische Unterstützung für Rate Limiting über Middleware.

Sichtbarkeit von Daten im Gateway: Da Traefik ausschließlich als Gateway fungiert und keine FHE-Bibliotheken verwendet, verarbeitet das Gateway lediglich die eingehenden HTTP-Anfragen und die darin enthaltenen Request-Payloads.

2.3 Key Lifecycle

Das Frontend verwendet TFHE.js und führt FHE-bezogene Operationen clientseitig aus.

Redis wird zur Speicherung von Schlüsseln verwendet. Die Schlüssel werden mit einer Time-to-Live (TTL) abgelegt.

Speicherung: Schlüssel werden in Redis gespeichert und mit einer TTL versehen.

Isolation:

- Wie die Isolation zwischen Sessions umgesetzt wird
- Wie Mandanten- oder Benutzertrennung erfolgt

2.4 Serialisierung

Für die APIs werden Rust-Datenstrukturen verwendet, die gleichzeitig zur automatischen OpenAPI-Generierung genutzt werden.

API-Schnittstellen: Die OpenAPI-Spezifikation wird automatisch mit `aide` und `schemars` aus den Rust-Datentypen erzeugt. Jeder Service stellt seine API-Dokumentation unter `/docs` bereit.

2.5 Build, Deployment, Tests

Build-Pipeline: Das Projekt wird als Cargo-Workspace und Monorepo organisiert.

Für die Containerisierung wird ein eigenes Docker-Image pro UC-Service verwendet. Die Images werden mittels Multi-Stage-Builds und `cargo-chef` erzeugt, um Abhängigkeiten zwischenspeichern und Buildzeiten zu reduzieren.

Zur Optimierung der FHE-Leistung wird die `tfhe`-Crate bereits im Entwicklungsprofil mit `opt-level=3` kompiliert.

Für produktive Builds wird zusätzlich eine CPU-Optimierung über `target-cpu=znver5` genutzt.

CI/CD: Die CI/CD-Pipeline basiert auf GitHub Actions.

Wesentliche Bestandteile:

- Pfadbasierte Change Detection mittels `dorny/paths-filter`

- Clippy als verpflichtendes Qualitäts-Gate (-D warnings)
- Automatischer Patch-Version-Bump nach Merge auf main
- Veröffentlichung der Container-Images in GHCR
- Automatische Aktualisierung der Helm-Konfiguration
- Deployment über ArgoCD nach dem GitOps-Prinzip

Deployment: Das Deployment erfolgt auf einem k3s-Cluster.

Verwendete Infrastrukturkomponenten:

- Traefik (Gateway)
- ArgoCD (GitOps)
- KEDA (Scale-to-Zero)
- Redis
- Prometheus
- Grafana
- Tempo

Helm-Charts werden zur Verwaltung aller Kubernetes-Ressourcen verwendet.

Teststrategie: Die Teststrategie umfasst:

- Unit-Tests: Tests einzelner Komponenten und Funktionen innerhalb der Services.
- Integrationstests: Tests der Endpunkte und des Zusammenspiels mehrerer Komponenten. Die Integrationstests werden im Release-Modus ausgeführt, um realistische Laufzeiten für FHE-Operationen zu gewährleisten.
- FHE-Korrektheitstests: FHE-Ergebnisse werden gegen Klartextreferenzen validiert.

Testausführung:

- `cargo nextest` als Test-Runner
- `cargo llvm-cov` zur Ermittlung der Testabdeckung
- Ausführung mit `--test-threads=1`, um Speicherprobleme durch parallele ServerKey-Dekompression zu vermeiden

Testabdeckung: Die Testabdeckung wird über `cargo llvm-cov` ermittelt.

Hinzufügen eines neuen Services:

1. Neuer Rust-Service als Crate im Cargo-Workspace anlegen.
2. Shared Crates als Dependencies einbinden.

3. Dockerfile und Helm-Chart ergänzen.
4. Routing-Konfiguration im Gateway erweitern.
5. GitHub-Action-Pipeline aktualisieren.
6. Deployment über ArgoCD automatisch ausrollen.

3 Use-Cases

3.1 Encrypted-Key-Value-Store

3.1.1 Funktionsbeschreibung

3.1.2 OpenAPI-Schnittstelle

3.1.3 Trust- und Threat-Model

3.1.4 FHE-Designentscheidungen

3.1.5 Komplexität der eigenen Algorithmen

3.1.6 Performance-Messung

3.1.7 Limitationen

3.2 Encrypted-Age-Verification

3.2.1 Funktionsbeschreibung

Der Use Case Encrypted Age Verification löst das Problem, das Alter einer Person serverseitig zu prüfen, ohne dass der Server den tatsächlichen Alterswert jemals im Klartext zu Gesicht bekommt. Das Ergebnis der Prüfung (volljährig: ja/nein) wird ebenfalls verschlüsselt zurückgegeben - der Server kennt weder Eingabe noch Ausgabe.

Das Alter wird bereits auf dem Client mit dem ClientKey verschlüsselt und ausschließlich in verschlüsselter Form an das Backend übertragen. Das Backend führt die Altersüberprüfung mittels Fully Homomorphic Encryption (TFHE) durch, ohne den zugrunde liegenden Alterswert entschlüsseln zu können. Die Entschlüsselung des Ergebnisses ist ausschließlich durch den Besitzer des ClientKeys möglich.


Akteure:

- Client: Generiert das TFHE-Schlüsselpaar, verschlüsselt das Alter mit dem ClientKey, sendet `encrypted_age` und `server_key` an den Server, empfängt das verschlüsselte Ergebnis und entschlüsselt es lokal. Der Client besitzt den ClientKey und ist der einzige Akteur, der das Ergebnis entschlüsseln kann.
- Backend (Server): Empfängt `encrypted_age` und `CompressedServerKey`, setzt den ServerKey, führt die homomorphe Altersüberprüfung (`age_check`) durch und gibt das verschlüsselte Ergebnis (`FheBool`) zurück. Der Server sieht zu keinem Zeitpunkt das Alter oder das Ergebnis im Klartext.

Lebenszyklus einer Session: Da dieser Use Case vollständig zustandslos ist, gibt es keine persistente Session. Der gesamte Ablauf findet innerhalb eines einzelnen HTTP-Requests statt:

1. Vorbereitung (Client): Client generiert ClientKey und CompressedServerKey lokal. Das Alter wird als `FheInt8` mit dem ClientKey verschlüsselt. Beide Werte werden bincode-serialisiert und base64-kodiert.
2. Request: Client sendet POST / mit `encrypted_age` und `server_key` als JSON-Body.
3. Verarbeitung (Server): Server dekodiert und deserialisiert beide Felder, setzt den ServerKey im globalen Thread-Kontext und führt `age_check` aus: `enc_age.gt(17) & enc_age.ge(0)`.
4. Response: Server serialisiert das `FheBool`-Ergebnis, base64-kodiert es und gibt es als `is_adult` zurück.
5. Auswertung (Client): Client dekodiert und deserialisiert `is_adult`, entschlüsselt das `FheBool` mit dem ClientKey und erhält das boolesche Ergebnis.

Verhaltensdiagramm:



3.2.2 OpenAPI-Schnittstelle

Der Service stellt eine einzelne verschlüsselte Verifikations-API bereit. Die OpenAPI-Definition wird automatisch generiert und ist unter `/openapi.json` sowie `/docs` (Swagger UI) erreichbar.

Im gesamten Service wird der `ServerKey` als `CompressedServerKey` übertragen (bincode-serialisiert, base64-kodiert).

POST /: Führt eine verschlüsselte Altersverifikation durch.

Request:

```
{
  "encrypted_age": "string",
  "server_key": "string"
}
```

Response 200:

```
{
  "is_adult": "string"
}
```

`is_adult` ist ein base64-kodierter, bincode-serialisierter `FheBool` - `true` wenn `Alter ≥ 18` und `≥ 0`.

Fehlercodes:

- 400 - Ungültiges Base64 oder beschädigtes bincode in server_key oder encrypted_age
- 500 - Serialisierungsfehler beim Kodieren des Ergebnisses

Body-Limit: 2 GiB (notwendig wegen der Größe des CompressedServerKey)

3.2.3 Trust- und Threat-Model

	Server klar	Server verschlüsselt	Nur Client
Alter (numerischer Wert)		X	
Ergebnis (volljährig: ja/nein)		X	
ServerKey / CompressedServerKey	X		X
ClientKey			X

Analyse: Beobachtbare Metadaten: TFHE schützt ausschließlich den Inhalt des Alters und des Ergebnisses. Für den Server bleiben weiterhin verschiedene Metadaten sichtbar:

- Zeitpunkte und Häufigkeit der Anfragen
- IP-Adresse des anfragenden Clients
- Charakteristische Payload-Größe (80 MB), die auf TFHE-Schlüsselübertragung schließen lässt
- Anzahl der Anfragen pro IP

Da age_check eine datenunabhängige Berechnung ist (keine Branches auf verschlüsselten Werten), gibt es kein Timing-Side-Channel über die Rechendauer. Ein Server-Operator kann aus den Metadaten allenfalls Nutzungshäufigkeit ableiten, nicht jedoch das Alter einzelner Nutzer.

Restvertrauen in den Server: Der Server kann zwar das Alter nicht entschlüsseln, muss jedoch weiterhin als korrekter Ausführer der Verifikationslogik vertrauenswürdig sein. Insbesondere wird angenommen, dass der Server:

- age_check korrekt und unverändert ausführt (kein Austausch gegen eine Funktion, die immer true zurückgibt)
- Das korrekte FheBool-Ergebnis zurücksendet und es nicht durch einen manipulierten Ciphertext ersetzt
- Den ServerKey nicht persistiert oder weitergibt

TFHE reduziert somit die Vertrauensabhängigkeit hinsichtlich der Inhaltsvertraulichkeit, ersetzt jedoch kein vollständig vertrauensloses Protokoll.

Annahmen außerhalb von TFHE: Die Sicherheitsbetrachtung basiert auf folgenden Annahmen:

- Die Kommunikation zwischen Client und Server erfolgt über TLS.

- Der Client führt Verschlüsselung und Entschlüsselung korrekt aus.
- Die verwendete TFHE-rs-Bibliothek wird als kryptographisch korrekt implementierte Black Box betrachtet.
- Es gibt keine Authentifizierung am Endpunkt: Jeder, der einen gültigen `CompressedServerKey` besitzt, kann Anfragen stellen.

Schutzversprechen: Durch den Einsatz von TFHE wird garantiert:

- Der Server kann das Alter des Nutzers nicht im Klartext lesen.
- Der Server kann nicht feststellen, ob das Ergebnis `true` oder `false` ist.
- Das Alter wird ausschließlich verschlüsselt verarbeitet.

Nicht garantiert werden:

- Schutz vor einem Server, der `age_check` durch eine manipulierte Funktion ersetzt
- Schutz vor Traffic-Analyse (Payload-Größe, Timing)
- Authentizität des Clients (kein ZKP, dass der Client den `ServerKey` korrekt erzeugt hat)

Konkret bedeutet das: Der Server kennt nicht das Alter des Nutzers und kann nicht feststellen, ob das Ergebnis positiv oder negativ ausgefallen ist. Sichtbar bleiben ausschließlich Zeitpunkt, Herkunft und Häufigkeit der Anfragen.

3.2.4 FHE-Designentscheidungen

Verwendete TFHE-rs-Typen: Für das Alter wird `FheInt8` (vorzeichenbehaftetes 8-Bit-Integer, Wertebereich -128 bis 127) verwendet. Diese Wahl ergibt sich aus zwei Gründen:

Altersangaben in Jahren liegen typischerweise im Bereich 0-127, also weit innerhalb von `i8`. `FheUInt8` wäre für den positiven Ast ausreichend, aber `FheInt8` erlaubt es, negative Eingaben explizit als ungültig zu erkennen und abzufangen (s. `is_positive-Check`). Zudem unterstützt `FheInt8` `gt` und `ge` mit vorzeichenbehafteter Ganzzahlssemantik, was den Negativen-Grenzwert-Test (`ge(0)`) korrekt macht.

Das Ergebnis ist ein `FheBool` (verschlüsseltes Bit), was dem binären Charakter der Frage (volljährig: ja/nein) entspricht.

Verwendete homomorphe Operationen: Der Server führt ausschließlich zwei Vergleiche und eine boolesche Verknüpfung aus. Andere homomorphe Operationen werden nicht benötigt, dadurch bleibt die serverseitige Auswertung auf die minimal nötige Anzahl FHE-Operationen beschränkt.

Operation	Verwendung
<code>FheInt8::gt</code>	<code>enc_age > 17</code> → Alter ≥ 18
<code>FheInt8::ge</code>	<code>enc_age > 0</code> → kein negativer Wert
<code>FheBool::bitand</code>	Verknüpfung beider Bedingungen

Verworfen Alternativen: `FheUInt8` statt `FheInt8`

Wäre für rein positive Eingaben ausreichend. Verworfen, weil damit keine sinnvolle Behandlung negativer Eingaben möglich ist - `FheUInt8` interpretiert `-1` als `255`, was den Negativen-Grenzwert-Test (`age_check(-1)` $\rightarrow$ `false`) unmöglich machen würde.

Schwellwert als verschlüsselter Parameter

Denkbar wäre, den Grenzwert (18) ebenfalls als `FheInt8` zu übergeben, um ihn serverseitig variabel zu halten. Verworfen, weil der Schwellwert in diesem Use Case keine schützenswerte Information ist und eine feste Konstante die Implementierung erheblich vereinfacht.

`FheInt32` oder größere Typen

Größere Bitbreiten würden höhere Latenzen pro homomorpher Operation verursachen, ohne Mehrwert - Altersangaben benötigen keine mehr als 8 Bit.

3.2.5 Komplexität der eigenen Algorithmen

Da der Use Case ausschließlich aus einer festen Anzahl homomorpher Operationen auf einem einzelnen Ciphertext besteht, gibt es keine parametrisierten Eingabegrößen. Die Komplexität aller Funktionen ist konstant.

Funktion	Zeitkomplexität	Platzkomplexität
<code>decode_server_key</code>	$O(1)$	$O(1)$
<code>decode_encrypted_age</code>	$O(1)$	$O(1)$
<code>age_check</code>	$O(1)$	$O(1)$
<code>encode_result</code>	$O(1)$	$O(1)$
<code>verify_age</code> (gesamt)	$O(1)$	$O(1)$

`verify_age` - $O(1)$, $O(1)$

Die Funktion führt genau zwei Vergleiche (`gt(17)`, `ge(0)`) und eine AND-Verknüpfung (`&`) auf einem `FheInt8`-Wert durch. Alle drei sind Operationen fester Bitbreite (8 Bit) auf einem einzelnen Ciphertext - unabhängig von jeder Eingabegröße. Gemäß der Konvention, homomorphe Operationen als $O(1)$ zu zählen, ist `age_check` $\in O(1)$.

Die De- und Serialisierungsschritte (`bincode`, `base64`) operieren auf Byte-Arrays fester Länge (durch die TFHE-rs-Typen bestimmt) und sind ebenfalls $O(1)$ bezüglich fachlicher Parameter.

3.2.6 Performance-Messung

Mess-Setup & Methodik

Die Performance- und Stresstests wurden auf einem virtuellen KVM-Server von Netcup durchgeführt. Die Last wurde extern mittels `k6` von einer lokalen Windows-Maschine über das Internet injiziert.

Es wurde ein einziger relevanter Endpunkt getestet: `POST /`. Alle anderen Endpunkte (`/health`, `/docs`) stellen nur Grundrauschen dar und wurden nicht gemessen.

Die gemessene Gesamtlatenz setzt sich daher aus drei Anteilen zusammen:

1. Netzwerkübertragung des 80 MB `ServerKey` (dominanter Anteil bei Remote-Messung)
2. `CompressedServerKey::decompress()` - rechenintensive Dekomprimierung
3. `age_check()` - zwei FHE-Vergleiche + AND-Verknüpfung

Die gemessenen Latenzen spiegeln den realistischen End-to-End-Overhead des zustandslosen Designs wider.

- Tool: k6 v2.0.0
- TFHE: ConfigBuilder::default()
- Datum: 05.06.2026
- Server: Netcup KVM

Test 1 - Baseline (1 VU, 10 sequentielle Requests) (05.06.2026)

Metrik	Wert
p50	13.65 s
p90	29,26 s
p95	43,51 s
Maximum	60,00 s
Fehlerrate	0%
Durchsatz	0,05 req/s

Fazit von Test 1:

Bereits bei einem einzelnen sequentiellen Client ist die Latenz hoch. Der dominierende Faktor ist die Übertragung des 80 MB ServerKey über das Internet sowie dessen Dekomprimierung. Die hohe Varianz zwischen p50 (13,65 s) und p95 (43,51 s) deutet darauf hin, dass Netzwerkschwankungen einen erheblichen Einfluss haben.

Test 2 - Stresstest (ramping bis 10 VUs) (05.06.2026, 3 Durchläufe)

Der Test wurde dreimal unabhängig voneinander ausgeführt. Die Tabelle zeigt Mittelwerte sowie die beobachtete Spanne zur Einordnung der Varianz.

Metrik	Lauf 1	Lauf 2	Lauf 3	Mittelwert
p50	13,65 s	13,70 s	13,59 s	13,65 s
p90	37,23 s	39,76 s	27,02 s	34,67 s
p95	43,51 s	52,74 s	30,69 s	42,31 s
Maximum	60,00 s	54,56 s	42,78 s	52,45 s
Fehlerrate	30 %	26 %	35 %	30 %
Durchsatz	0,05 req/s	0,05 req/s	0,05 req/s	0,05 req/s

Fazit von Test 2:

Unter paralleler Last liegt die Fehlerrate im Mittel bei 30%. Die Fehler sind ausschließlich HTTP 499 (Client Closed Request) und HTTP 504 (Gateway Timeout) - der vorgelagerte Nginx-Proxy trennt Verbindungen nach 60 s, bevor der Server die Verarbeitung abschließen kann. Der Server selbst lief in allen drei Durchläufen vollständig stabil und verarbeitete alle Anfragen ohne eigene Fehler.

Der p50 ist mit 13,6 s über alle Läufe sehr stabil - das ist die reine Verarbeitungszeit eines einzelnen Requests ohne Mutex-Wartezeit. Die hohe Varianz bei p95 (30-52 s) und der Fehlerrate (26-35%) ist dagegen direkt auf Netzwerkschwankungen bei der Übertragung des 80 MB großen ServerKey zurückzuführen. Je nach Netzwerklast zum Messzeitpunkt verschiebt sich der Anteil der Requests, die den Proxy-Timeout überschreiten.

Die Throughput-Grenze liegt bei einem parallelen Request. Jeder weitere gleichzeitige Request verlängert die Wartezeit linear, da `tfhe::set_server_key` einen globalen Thread-Kontext

setzt und die gesamte Verarbeitung (Übertragung + Dekomprimierung + FHE) serialisiert wird. Ab 2 VUs überschreitet p95 den Proxy-Timeout von 60 s regelmäßig.

3.2.7 Limitationen

- Der Use Case ist vollständig zustandslos. Es gibt keine Session, keine Audit-Log und keine Möglichkeit, Ergebnisse serverseitig zu speichern oder abzurufen.
- Der `CompressedServerKey` (80 MB) wird bei jedem einzelnen Request vom Client mitgeschickt, deserialisiert und dekomprimiert. Dieses Design ist eine direkte Konsequenz der Zustandslosigkeit: Da jeder Client sein eigenes Schlüsselpaar generiert, kann kein globaler `ServerKey` serverseitig gespeichert werden, ohne das Sicherheitsmodell zu brechen. Ein gespeicherter `ServerKey` eines anderen Clients würde es diesem ermöglichen, fremde Ergebnisse zu entschlüsseln. Die Folge ist, dass Netzwerkübertragung und Dekomprimierung die Latenz dominieren und ein produktiver Einsatz über das Internet praktisch nicht skaliert.
- Der Server prüft nicht, ob ein `encrypted_age`-Ciphertext bereits zuvor verwendet wurde. Ein Angreifer, der einen Ciphertext abfängt, kann ihn beliebig oft einreichen.
- Der Client übergibt den `CompressedServerKey` selbst. Ein böartiger Client könnte einen manipulierten Key einreichen. In einer produktiven Umgebung müsste der `ServerKey` serverseitig fest hinterlegt sein.
- Der Client könnte einen beliebigen `FheInt8`-Wert übermitteln - der Server kann nicht verifizieren, dass die verschlüsselte Eingabe tatsächlich ein Alter darstellt oder aus einer vertrauenswürdigen Quelle stammt (kein Zero-Knowledge-Beweis).
- Maximal darstellbarer Alterswert ist 127 Jahre (`i8::MAX`). Dies ist für den Anwendungsfall ausreichend, aber die Wahl von `FheInt8` schließt größere Ganzzahlen strukturell aus.
- Es gibt keine Authentifizierung am Endpunkt. Jeder, der die API kennt, kann Anfragen stellen. Ein Gateway-Layer (z. B. API-Key, mTLS) ist in der aktuellen Implementierung nicht vorhanden.
- Durch den globalen `set_server_key`-Aufruf ist echte Parallelverarbeitung nicht möglich. Der Durchsatz skaliert nicht mit der Anzahl der CPU-Kerne.

3.3 Encrypted-Voting-&-Polling

3.3.1 Funktionsbeschreibung

Der Use Case Voting/Polling ermöglicht die Durchführung vertraulicher Abstimmungen zwischen mehreren Teilnehmern. Ziel ist es, Abstimmungsergebnisse auszuwerten, ohne dass der Server Zugriff auf die einzelnen Stimmen der Teilnehmer erhält.

Hierzu werden Stimmen bereits auf dem Client verschlüsselt und ausschließlich in verschlüsselter Form an das Backend übertragen. Das Backend verarbeitet und aggregiert die verschlüsselten Stimmen mittels Fully Homomorphic Encryption (TFHE), ohne die zugrunde liegenden Klartexte entschlüsseln zu können. Die Entschlüsselung der aggregierten Ergebnisse ist ausschließlich durch den Besitzer des ClientKeys möglich.

Der Use Case unterstützt die Fragetypen Single Choice, Multiple Choice und Numeric. Eine Abstimmungssession kann beliebig viele Fragen enthalten und von mehreren Teilnehmern genutzt werden.

Akteure:


- **Ersteller (Client E):** Der Ersteller generiert das TFHE-Schlüsselpaar, definiert die Fragen und erstellt die Voting-Session. Zusätzlich verwaltet er die Teilnahme der Nutzer (Genehmigung oder Ablehnung). Der Client E besitzt den ClientKey und ist der einzige Akteur, der Ergebnisse entschlüsseln kann.
- **Teilnehmer (Client):** Ein Teilnehmer kann einer Session beitreten, indem er die Session-ID und seinen verschlüsselten Namen an den Server sendet. Nach Genehmigung durch den Ersteller kann der Teilnehmer seine Stimme(n) abgeben. Sowohl Name als auch Stimme werden clientseitig mit dem PublicKey verschlüsselt und an den Server übertragen. Teilnehmer können zu keinem Zeitpunkt die aggregierten Ergebnisse einsehen.
- **Backend (Server):** Der Server verwaltet Sessions, Teilnehmerstatus und gespeicherte Ciphertexts. Er führt homomorphe Aggregationen auf verschlüsselten Stimmen durch, hat jedoch keinen Zugriff auf Klartextinformationen von Namen oder Stimmen.

Lebenszyklus einer Session:

- **Erstellung:** Der Ersteller generiert ein TFHE-Schlüsselpaar und erstellt eine Session mit eindeutiger UUID. Der PublicKey und ServerKey werden an das Backend übergeben, der ClientKey verbleibt ausschließlich beim Ersteller in der Session Storage.
- **Teilnahme:** Teilnehmer gibt Session-ID und Name ein und klickt auf Beitreten. Das Frontend versucht den PublicKey aus der Session Storage abzurufen, falls er dort noch nicht vorliegt, wird er vom Backend geladen und in der Session Storage gespeichert. Mit dem PublicKey wird der Name verschlüsselt und eine Beitrittsanfrage an den Server gesendet. Der Status ist zunächst pending.
- **Genehmigung:** Der Ersteller entschlüsselt den Teilnehmernamen und genehmigt oder lehnt die Teilnahme ab. Der Teilnehmerstatus wird serverseitig aktualisiert.

- **Abstimmung:** Genehmigte Teilnehmer beantworten die Fragen der Session und geben ihre Stimme ab. Ihre Stimmen werden mit dem PublicKey verschlüsselt und an den Server gesendet. Der Server speichert ausschließlich Ciphertexts.
- **Auswertung:** Nachdem der Ersteller auf "Auswertung anzeigen" klickt, wird geprüft, ob alle zugelassenen Teilnehmer bereits abgestimmt haben bzw. ob mindestens ein Vote vorhanden ist. Wenn dies der Fall ist, aggregiert der Server alle verschlüsselten Stimmen mittels homomorpher Addition und stellt die aggregierten Ciphertexts dem Ersteller zur Verfügung. Der Ersteller kann zu jedem Zeitpunkt versuchen die aktuell aggregierten Ergebnisse vom Server abzurufen und lokal zu entschlüsseln, bis die Session finalisiert wurde.
- **Schließen:** Die Session bleibt aktiv, bis der Ersteller sie explizit als finalized markiert oder bei 10 Minuten Inaktivität. Bis zu diesem Zeitpunkt können Teilnehmer der Session beitreten und nach Genehmigung Stimmen abgeben, und alle eingehenden Votes werden in die Aggregation einbezogen. Mit der Finalisierung wird die Session vollständig geschlossen. Ab diesem Zeitpunkt:
 - Können keine neuen Teilnehmer mehr beitreten
 - Können keine weiteren Stimmen abgegeben werden
 - Wird der Client aus der Manage-Session-Ansicht heraus zur Startseite weitergeleitet

Verhaltensdiagramm:



3.3.2 OpenAPI-Schnittstelle

Der Service stellt eine fachliche Voting-/Polling-API bereit, mit der Sessions erstellt, Teilnehmer verwaltet und verschlüsselte Stimmen abgegeben werden können. Die OpenAPI-Definition wird automatisch generiert und ist unter `/openapi.json` sowie `/docs` (Swagger UI) verfügbar.

Im gesamten Service wird der `PublicKey` als `CompressedPublicKey` verwendet. Dieser ermöglicht eine Batch-Verschlüsselung.

POST /session Legt eine neue Voting-Session an.

Request:

```
{
  "creator_id": "string",
  "server_key": "string",
  "public_key": "string | null",
  "questions": [
    {
      "id": 0,
      "text": "string",
      "question_type": "single | multiple | numeric",
      "options": ["string"]
    }
  ]
}
```

Response 200:

```
{
  { "session_id": "uuid" }
}
```

Fehlercodes: 400 – Invalid Base64 oder beschädigtes bincode im `server_key`

GET /session/session_id - Gibt die Metadaten einer Session für Teilnehmer zurück.

Response 200

```
{
  {
    "session_id": "uuid",
    "questions": [
      {
        "id": 0,
        "text": "string",
        "question_type": "single | multiple | numeric",
        "options": ["string"]
      }
    ],
    "public_key": "string | null"
  }
}
```

Fehlercodes: 400 – Session nicht gefunden

POST/JOIN Teilnehmer beantragt den Beitritt zu einer Session. Der Beitritt ist zunächst pending und muss vom Creator freigegeben werden. **Response 200**

```
{
  {
    "session_id": "uuid",
    "participant_id": "string",
    "enc_name_chunks": ["string"]
  }
}
```

Response 200

```
{
  { "status": "pending" }
}
```

Fehlercodes

404 – Session nicht gefunden

409 – Session bereits beendet

POST/APPROVE

Der Creator genehmigt oder lehnt Teilnehmer ab. **Request**

```
{
  {
    "session_id": "uuid",
    "creator_id": "string",
    "participant_id": "string",
    "approved": true
  }
}
```

Response 200

```
{
  { "status": "ok" }
}
```

Fehlercodes

404 – Session nicht gefunden

403 – Nicht autorisiert (falscher creator_id)

409 – Session bereits beendet

404 – Teilnehmer nicht gefunden (nur bei approval=true relevant)

POST /vote

Ein genehmigter Teilnehmer sendet seine verschlüsselten Votes.

```
{
  {
    "session_id": "uuid",
```

```

        "participant_id": "string",
        "encrypted_votes": [
            "string",
            "string"
        ]
    }
}

```

Response 200

```

{
  { "status": "vote received" }}
}

```

Fehlercodes

404 – Session nicht gefunden

404 – Teilnehmer nicht gefunden

403 – Teilnehmer nicht genehmigt

409 – Session bereits beendet

400 – Anzahl der Votes stimmt nicht mit Fragen überein

GET /status/session_id/participant_id

Liefert den aktuellen Status eines Teilnehmers.

Response 200

```

{
  [
    {
      "participant_id": "string",
      "approved": true,
      "has_voted": false,
      "enc_name_chunks": ["string"]
    }
  ]
}

```

Fehlercodes

404 – Session nicht gefunden

403 – Nicht autorisiert

GET /results/session_id/creator_id Gibt die homomorph aggregierten Ergebnisse zurück (nur Creator). Wenn noch nicht alle Votes vorhanden sind, ist ready = false.

Response (ready)

```

{
  {
    "encrypted_results": [
      "string"
    ],

```

```

        "ready": true
    }
}

```

Response (not ready)

```

{
  {
    "encrypted_results": [],
    "ready": false
  }
}

```

Fehlercodes

404 – Session nicht gefunden

403 – Nicht autorisiert

POST /finalize/session_id/creator_id

Schließt die Session endgültig. Danach sind keine Votes oder Joins mehr möglich.

Response 200

```

{
  { "status": "finalized" }
}

```

Fehlercodes

404 – Session nicht gefunden

403 – Nicht autorisiert

409 – Session bereits finalisiert

3.3.3 Trust- und Threat-Model

Datum	Am Server klar	Am Server verschlüsselt	Am Client
Session_id (UUID)	X		X
Creator_id	X		X
Participant_id	X		X
Fragen	X		X
Antwortoptionen	X		X
Teilnehmerstatus	X		X
Abstimmungszeitpunkte	X		X
Anzahl Teilnehmer/Votes	X		X
Session State (finalized)	X		X
Public Key der Session	X		X
Server Key	X		X
Teilnehmernamen (verschlüsselt)		X	X

Datum	Am Server klar	Am Server verschlüsselt	Am Client
Teilnehmernamen (entschlüsselt)			X
Vote Inhalt		X	
Aggregierte Ergebnisse (verschlüsselt)		X	X
Aggregierte Ergebnisse (entschlüsselt)			X
Client Key			X

Analyse: Beobachtbare Metadaten

TFHE schützt ausschließlich die Inhalte von Stimmen und Ergebnissen. Für den Server bleiben weiterhin verschiedene Metadaten sichtbar:

- Anzahl und Aktivität von Sessions
- Anzahl der Teilnehmer pro Session
- Anzahl abgegebener Stimmen
- Zeitpunkte von Beitritt, Genehmigung und Abstimmung
- Request-Timing und Voting-Pattern
- Umfragestruktur (Fragen und Antwortoptionen)
- Teilnehmerstatus (pending, approved, has_voted)
- Polling-Verhalten der Admin-Oberfläche

Ein Server-Operator kann daraus Rückschlüsse auf Aktivitätsmuster, soziale Dynamiken, die Größe einer Abstimmung oder mögliche Zusammenhänge zwischen Abstimmungszeitpunkten und Teilnehmerverhalten ziehen.

Der Server kann zwar keine Stimmen entschlüsseln, muss jedoch weiterhin als korrekter Ausführer des Protokolls vertrauenswürdig sein. Insbesondere wird angenommen, dass der Server:

- Teilnehmer korrekt Sessions zuordnet
- Join- und Approval-Prozesse korrekt verarbeitet
- Stimmen vollständig speichert und nicht verwirft
- Sessions voneinander trennt
- Homomorphe Aggregationen korrekt ausführt
- Die Verfügbarkeit des Systems sicherstellt

TFHE reduziert somit die Vertrauensabhängigkeit hinsichtlich der Inhaltsvertraulichkeit, ersetzt jedoch kein vollständig vertrauensloses Protokoll.

Annahmen außerhalb von TFHE

Die Sicherheitsbetrachtung basiert auf folgenden Annahmen:

- Die Kommunikation zwischen Client und Server erfolgt über TLS.
- Das Frontend führt die Verschlüsselung und Entschlüsselung korrekt aus.
- Die verwendete TFHE-rs-Bibliothek wird als kryptographisch korrekt implementierte Black Box betrachtet. Der ClientKey verbleibt ausschließlich beim Session-Ersteller.

Das System besitzt keine starke Benutzerauthentifizierung, die Teilnahme erfolgt ausschließlich über Session-ID und frei gewählten Namen.

Schutzversprechen

Durch den Einsatz von TFHE wird garantiert:

- Der Server kann individuelle Stimmen nicht im Klartext lesen.
- Der Server kann einzelne Abstimmungsentscheidungen nicht rekonstruieren.
- Stimmen werden ausschließlich verschlüsselt verarbeitet. Auch aggregierte Ergebnisse liegen auf dem Server nur verschlüsselt vor.

Nicht garantiert werden:

- Vertraulichkeit der Umfragestruktur
- Vertraulichkeit von Metadaten und Abstimmungszeitpunkten
- Schutz vor Traffic- und Timing-Analysen
- Schutz vor aktiv manipulierendem Serververhalten
- Fairness oder Vollständigkeit der Protokollausführung

Konkret bedeutet das: Der Server kennt nicht den Inhalt einer abgegebenen Stimme und kann nicht feststellen, welche Antwort ein Teilnehmer gewählt hat. Sichtbar bleiben jedoch Existenz, Zeitpunkt und organisatorischer Kontext der Abstimmung.

Einordnung

Der Use Case implementiert ein TFHE-geschütztes Abstimmungssystem mit Vertraulichkeit auf Inhaltsebene. Geschützt werden ausschließlich individuelle Stimmen und deren aggregierte Ergebnisse. Metadaten, Umfragestruktur und der allgemeine Kontrollfluss der Anwendung bleiben außerhalb des Schutzbereichs von TFHE.

3.3.4 FHE-Designentscheidungen

Verwendete TFHE-rs-Typen

Für die Repräsentation der Stimmen wird primär der Datentyp FheUInt32 verwendet. Obwohl die einzelnen Eingabewerte der Teilnehmer (z. B. bei numerischen Fragen oder kodierten Auswahlwerten) nur im Bereich 0 kleiner gleich x kleiner gleich 255 liegen und damit grundsätzlich mit FheUInt8 darstellbar wären, wurde bewusst ein größerer Datentyp gewählt.

Der Grund liegt in der homomorphen Aggregation der Stimmen. Alle Einzelwerte werden serverseitig addiert, wodurch das Ergebnis deutlich größere Werte annehmen kann als der ursprüngliche Eingabebereich. Bei k Teilnehmern ergibt sich im Worst Case: $255 \times k$

Um Überläufe sicher auszuschließen und eine einheitliche Verarbeitung aller Fragetypen zu gewährleisten, wird daher FheUint32 sowohl für Einzelstimmen als auch für aggregierte Ergebnisse verwendet. Dies vereinfacht zusätzlich die Implementierung, da kein Typwechsel zwischen Eingabe und Auswertung erforderlich ist.

Für Teilnehmernamen wird dagegen FheUint8 verwendet. Jeder Buchstabe wird als ASCII-Zeichenwert (0–255) verschlüsselt und einzeln gespeichert. Da Zeichenwerte innerhalb dieses Bereichs liegen, ist ein größerer Datentyp hierfür nicht erforderlich.

Verwendete homomorphe Operationen

Der Server führt ausschließlich homomorphe Additionen auf verschlüsselten Stimmen aus. Für jede Frage werden die verschlüsselten Stimmen aller Teilnehmer aufsummiert. Bei Single-Choice- und Multiple-Choice-Fragen erfolgt die Addition komponentenweise für jede Antwortoption. Andere homomorphe Operationen werden nicht benötigt, dadurch bleibt die serverseitige Auswertung auf die einfachste benötigte FHE-Operation beschränkt.

Verworfen Alternativen

Separate Bool-Fragen (FheBool)

Ursprünglich war vorgesehen, Ja/Nein-Fragen als eigene Kategorie abzubilden. Diese Variante wurde verworfen. Stattdessen können Ja/Nein-Fragen als Single-Choice-Fragen mit den Antwortoptionen „Ja“ und „Nein“ modelliert werden.

Dadurch müssen alle Fragen zwingend beantwortet werden und die Auswertung aller Auswahlfragen kann über denselben Algorithmus erfolgen. Zudem entfällt die Notwendigkeit, unterschiedliche verschlüsselte Datentypen (FheBool und FheUint32) parallel zu unterstützen. Die Implementierung verwendet somit ausschließlich FheUint32 für die Repräsentation von Stimmen.

FheUint8 als Speichertyp für Stimmen

FheUint8 wäre für einzelne Stimmen semantisch korrekt, da Eingabewerte auf 0–255 begrenzt sind. Dieser Ansatz wurde jedoch verworfen, da die homomorphe Aggregation schnell zu Überläufen führen würde.

Stattdessen wird einheitlich FheUint32 verwendet, um sowohl Einzelwerte als auch Summen sicher darzustellen.

Gleitkommazahlen

Gleitkommazahlen wurden als naheliegende Repräsentation für numerische Eingaben verworfen, da TFHE primär auf Ganzzahlarithmetik ausgelegt ist. Insbesondere Divisionen und Floating-Point-Operationen sind entweder nicht vorgesehen oder ineffizient. Daher erfolgt die Modellierung aller Werte als Ganzzahlen (FheUint32).

3.3.5 Komplexität der eigenen Algorithmen

- n : Anzahl der Fragen einer Abstimmung
- k : Anzahl der Teilnehmer bzw. abgegebenen Stimmen
- m : Anzahl der Antwortoptionen einer Single- oder Multiple-Choice-Frage

Die interne Komplexität der TFHE-rs-Bibliothek wird nicht betrachtet; jede homomorphe Operation wird gemäß Aufgabenstellung als $O(1)$ angenommen.

Funktion	Zeitkomplexität	Platzkomplexität
create_session	$O(n)$	$O(n)$
join_session	$O(1)$	$O(1)$
approve_participant	$O(1)$	$O(1)$
submit_vote	$O(nm)$	$O(nm)$
aggregate_votes_ciphertext_only	$O(nkm)$	$O(m)$
get_results	$O(k + nkm)$	$O(nkm)$
finalize_session	$O(1)$	$O(1)$
get_status	$O(1)$	$O(1)$
get_session	$O(n)$	$O(n)$
get_participants	$O(k)$	$O(k)$

Create_session – $O(n)$, $O(n)$

Beim Anlegen einer Session wird die übergebene Fragenliste gespeichert. Die übrigen Operationen (UUID-Erzeugung, Initialisierung leerer HashMaps, Einfügen in die Session-Map) besitzen konstante Laufzeit. Da die Größe der Fragenliste proportional zu n ist, ergeben sich Zeit- und Platzkomplexität von $O(n)$.

Join_session – $O(1)$, $O(1)$

Die Session wird per HashMap-Lookup gefunden und ein neuer Teilnehmer in die Teilnehmer-HashMap eingefügt. Beide Operationen besitzen durchschnittlich konstante Laufzeit. Pro Aufruf wird nur ein zusätzlicher Teilnehmer gespeichert.

Approve_participant — $O(1)$, $O(1)$

Die Session und der Teilnehmer werden über HashMaps gefunden. Anschließend wird entweder ein Boolean gesetzt oder der Teilnehmer entfernt. Es erfolgt keine Iteration über Teilnehmer oder Stimmen.

Submit_vote -- $O(nm)$, $O(nm)$

Eine Stimme enthält für jede der n Fragen verschlüsselte Antworten. Bei Single-/Multiple-Choice-Fragen können pro Frage bis zu m verschlüsselte Optionen enthalten sein. Das Speichern der gesamten Stimmenstruktur benötigt daher Zeit und Speicher proportional zur Anzahl der übergebenen verschlüsselten Werte.

Aggregate_votes_ciphertext_only -- $O(nkm)$, $O(m)$

Für jede der n Fragen werden alle k Stimmen verarbeitet. Bei Single- oder Multiple-Choice-Fragen werden zusätzlich alle m Antwortoptionen aufsummiert. Daraus ergibt sich eine Zeitkomplexität von $O(n \cdot k \cdot m)$.

Der zusätzliche Speicher besteht lediglich aus dem Akkumulatorvektor für die aktuelle Frage und benötigt maximal m Einträge.

Get_results -- $O(k + nkm)$, $O(nkm)$

Zunächst werden alle Teilnehmer durchlaufen, um die Anzahl der freigegebenen Teilnehmer zu bestimmen ($O(k)$). Anschließend werden alle gespeicherten Stimmen kopiert und aggregiert. Die Aggregation dominiert mit $O(nkm)$. Für die Kopie aller Stimmen wird Speicher proportional zur Gesamtzahl gespeicherter Stimmen benötigt: $O(nkm)$

Finalize_session -- $O(1)$, $O(1)$

Die Session wird per HashMap gefunden und das Boolean-Feld finalized gesetzt. Es werden weder Schleifen noch zusätzliche Datenstrukturen verwendet.

Get_status -- $O(1)$, $O(1)$

Der Teilnehmerstatus wird über einen einzelnen HashMap-Zugriff bestimmt. Es erfolgt keine Iteration über andere Teilnehmer.

Get_session — $O(n)$, $O(n)$

Die Session wird per HashMap gefunden und die Fragenliste in die Antwort kopiert. Die Größe dieser Liste ist proportional zur Anzahl der Fragen n .

Get_participants -- $O(k)$, $O(k)$

Für die Antwort wird über alle Teilnehmer iteriert und für jeden ein ParticipantAdminView erzeugt. Jeder Teilnehmer wird genau einmal verarbeitet, daher ergibt sich eine lineare Laufzeit und Speicherbelegung in der Anzahl der Teilnehmer k .

3.3.6 Performance-Messung

Mess-Setup & Methodik

Die Performance- und Stresstests wurden auf einem virtuellen KVM-Server von Netcup mit dedizierten CPU-Ressourcen durchgeführt. Die Last wurde extern mittels k6 von einer lokalen Windows-Maschine über das Internet injiziert.

Es wurden zwei Testszenarien mit unterschiedlichen funktionalen Schwerpunkten untersucht:

- Teilnehmer-Anfragen: Analyse der Endpunkte (POST /join und GET /status), um das Systemverhalten bei einem Anstieg von Join-Anfragen und hochfrequentem Polling durch die Teilnehmer zu evaluieren.
- Ergebnisauswertung: Dedizierte Stressprüfung des Endpunkts GET /results/{session_id}/{creator_id} unter einer Dauerlast von konstant zehn parallelen Virtual Users (VUs). Um die CPU-Auslastung durch die kryptografischen Berechnungen gezielt zu maximieren, wurde das System vorab in einen Zustand versetzt, in dem die Bedingung `voted_count >= approved_count` dauerhaft erfüllt war. Dadurch wurde sichergestellt, dass jeder eingehende Request die rechenintensive homomorphe Aggregationsfunktion `aggregate_votes_ciphertext_only` vollständig durchläuft. Das Szenario wurde in zwei separaten Testläufen durchgeführt: zunächst mit zwei Teilnehmern und anschließend mit zehn Teilnehmern pro Session.

Performancetest 1 (Join und Polling) (08.06.2026)

Im ersten Testszenario wurde ein plötzlicher Anstieg der Teilnehmeraktivität simuliert. Die Anzahl der virtuellen Nutzer wurde innerhalb von zwei Sekunden von fünf auf 500 erhöht. Jeder Teilnehmer führte genau eine Join-Anfrage aus und wechselte anschließend in ein hochfrequentes Polling des Sitzungsstatus mit einem Intervall von 200 ms.

Fazit von Performancetest 1:

Während des gesamten Tests wurden insgesamt 105.675 HTTP-Anfragen verarbeitet. Dabei konnten keine fehlgeschlagenen Requests beobachtet werden. Sowohl die Join- als auch die

Metrik	join	status
p50	17,48 ms	17,16 ms
p90	21,92 ms	21,32 ms
p95	24,45 ms	25,02 ms
Maximum	41,86 ms	95,06 ms
Fehlerrate	0 %	0 %


Status-Endpunkte zeigten stabile Antwortzeiten im niedrigen zweistelligen Millisekundenbereich (Join: p95 = 24,45 ms; Status: p95 = 25,02 ms), sodass im untersuchten Lastbereich keine Hinweise auf Engpässe oder Skalierungsprobleme festgestellt werden konnten.

Performancetest 2: FHE-Ergebnisauswertung (03.06.2026)

Hierbei wurde die mathematisch rechenintensive homomorphe Aggregation evaluiert. Um den direkten Einfluss der Kryptographischen Komplexität zu untersuchen, wurde derselbe Stresstest bei dauerhaft 10 parallelen VUs in zwei getrennten Konfigurationen durchgeführt, einmal mit 2 hinterlegten Stimmen und einmal mit 10 hinterlegten Stimmen. Die Auswahl von genau 2 bzw. 10 Teilnehmern erfolgte, um einerseits die mathematische Grundlatenz zu bestimmen und andererseits die Skalierung der FHE-Operation unter moderater Gruppenlast zu überprüfen.

Metrik	2 Stimmen	10 Stimmen
p50	0,47 s	2,83 s
p90	0,51 s	8,31 s
p95	0,53 s	11,21 s
Maximum	0,76 s	14,32 s
Fehlerrate	0 %	0 %
Durchsatz	1,49 Request/s	0,90 Request/s

Während das System bei 2 Stimmen sehr schnell reagiert, führt die rechenintensive kryptografische Funktion `aggregate_votes_ciphertext_only` bei 10 Stimmen zu einer massiven Latenz von über 11 Sekunden im p95-Bereich. Diese Verzögerung resultiert aus der globalen Zustandssperre (`state.lock()`). Da dieser Mutex während der gesamten FHE-Berechnung gehalten wird, blockiert er die parallele Verarbeitung des Axum-Servers und führt zu einer sequenziellen Abarbeitung aller eingehenden Anfragen. Trotz dieser intensiven CPU-Auslastung arbeitet das Backend vollständig stabil und verarbeitet alle Anfragen ohne Fehlerraten.



n der Grafik findet sich die Testvariante mit 2 hinterlegten Stimmen im Bereich von ca. 12:17–12:22. Hier wird sichtbar, dass das System sehr schnell reagiert und p95 und p99 nahezu identisch verlaufen.

Die Variante mit 10 hinterlegten Teilnehmern findet sich im Bereich von ca. 12:26–12:30. Hier zeigt sich ein drastischer Umschwung im Systemverhalten: Die Latenzkurven für p95 und p99 brechen steil nach oben aus und bilden ein massives Plateau, das sich knapp unterhalb der 10-Sekunden-Marke einpendelt. Die grüne Median-Linie (p50) verläuft deutlich darunter im Bereich von knapp 3 Sekunden, was die Verteilung der Wartezeiten im eingetretenen Mutex-Stau exakt widerspiegelt. Der absolute Peak von 14,32 Sekunden wird kurz vor dem Ende des Testfensters als dünne, maximale Spitze der blauen p99-Kurve sichtbar. Nach dem harten Stopp der Last um Punkt 12:30 Uhr fällt die Latenz sofort wieder auf die Baseline von 0 Sekunden ab.

Zusammenfassend zeigen die Messergebnisse, dass die grundlegende REST-Infrastruktur des Backends (Test 1) optimal skaliert und im unverschlüsselten Zustand keinerlei Performance-Engpässe aufweist. Die eigentliche Skalierungsbremse des Systems liegt isoliert auf der kryptographischen Verarbeitungsebene (Test 2).

3.3.7 Limitationen

- Teilnehmende können bei numerischen Fragen ausschließlich Werte zwischen 0 und 255 als Antwort angeben. Höhere Zahlen lassen wir bewusst nicht zu, dementsprechend müssen Fragen eventuell anders definiert werden. Bsp: Wie hoch ist dein Jahregehalt in tausend €
- Es können keine Doppelabstimmungen verhindert werden. Ein Teilnehmer kann technisch mehrere Join-Requests mit unterschiedlichen Namen schicken und so mehrfach abstimmen. Stattdessen erfolgt die Kontrolle durch den Ersteller. Dadurch liegt die Verantwortung für die Verhinderung von Mehrfachteilnahmen bei ihm.

3.4 Sealed-Bid-Auction

3.4.1 Funktionsbeschreibung

Der Use Case Sealed-Bid Auction ermöglicht die Durchführung verdeckter Auktionen (Blin-dauctionen) zwischen mehreren Bietern. Ziel ist es, nach dem Ende der Bietphase den Höchstbietenden sowie den exakten Gewinnerbetrag zu ermitteln, ohne dass der Server zu irgendeinem Zeitpunkt die einzelnen Gebote der Teilnehmer im Klartext einsehen kann.

Hierzu werden die Gebotsbeträge bereits auf dem Client verschlüsselt und ausschließlich in verschlüsselter Form an das Backend übertragen. Das Backend verarbeitet und evaluiert die verschlüsselten Gebote mittels Fully Homomorphic Encryption (TFHE), ohne die zugrunde liegenden Klartexte kennen zu können. Die Entschlüsselung des finalen Auktionsgewinners ist ausschließlich durch den Besitzer des ClientKeys (den Auktionator) möglich.

Akteure:


- Auktionator (Client E): Der Auktionator initialisiert das TFHE-Schlüsselpaar, erstellt die Auktionsrunde und gibt die Auktion für die Bieter frei. Er besitzt den geheimen ClientKey und ist als einziger Akteur in der Lage, das vom Server homomorph berechnete Endergebnis (den Höchstbietenden und den Gewinnbetrag) lokal zu entschlüsseln.
- Bieter (Client): Ein Bieter kann der Auktion beitreten, indem er seinen Namen und sein verdecktes Gebot abgibt. Das Gebot wird clientseitig mit dem PublicKey als FheUint32 verschlüsselt. Bieter können zu keinem Zeitpunkt die Gebote anderer Teilnehmer oder den aktuellen Zwischenstand der Auktion einsehen.
- Backend (Server): Der Server verwaltet den Zustand der Auktion, speichert die eingehenden verschlüsselten Gebote flüchtig im RAM und stellt den PublicKey für neue Bieter bereit. Auf Anfrage führt er die rechenintensive, blinde Maximumsuche über homomorphe Größenvorzeichen-Operationen und Auswahlen durch, ohne Zugriff auf Klartextinformationen zu haben.

Lebenszyklus einer Session:

1. Erstellung: Der Auktionator generiert ein TFHE-Schlüsselpaar und startet die Auktion mit einer eindeutigen UUID. Der PublicKey und der komprimierte ServerKey werden an das Backend übergeben, der ClientKey verbleibt exklusiv im lokalen Session Storage des Auktionators.
2. Gebotsabgabe: Bieter rufen das Dashboard auf. Das Frontend lädt den PublicKey vom Server. Der Bieter gibt seinen Namen ein, das Frontend verschlüsselt den Betrag als FheUint32 und sendet den Payload an /auction/gebot. Der Server speichert den Namen im Klartext und das Gebot als Ciphertext im globalen RAM (Vec<Bid>).
3. Auswertung: Sobald die Bietphase beendet ist, klickt der Auktionator on „Gewinner berechnen“. Der Server prüft, ob Gebote vorhanden sind, und durchläuft anschließend eine homomorphe Schleife, um das absolute Maximum und den zugehörigen Namen ohne Entschlüsselung zu isolieren. Das verschlüsselte Ergebnis wird für den Auktionator hinterlegt.
4. Schließen & Finalisierung: Nach der Auswertung wird die Auktion als geschlossen markiert. Es werden keine neuen Gebote mehr akzeptiert. Der Auktionator ruft das

verschlüsselte Endergebnis ab, entschlüsselt es lokal mit seinem ClientKey und zeigt den Gewinner auf dem Dashboard an.

Verhaltensdiagramm:



3.4.2 OpenAPI-Schnittstelle

Die API bietet zwei REST-Endpunkte, welche semantisch als Request/Response via JSON konzipiert sind. Die kryptographischen Payloads sind per bincode serialisiert und in Base64 codiert.

POST /gebot Empfängt ein verschlüsseltes Gebot.

- Request Body (JSON):
 - bidder_name (String): Klartextname des Bieters.
 - encrypted_amount (String): Base64-codierter tfhe::FheUint32 Payload.
 - server_key (String): Base64-codierter tfhe::CompressedServerKey.
- Response (200 OK):
 - response (String): Erfolgsmeldung.
- Fehler (400 Bad Request):
 - Tritt auf, wenn Base64 nicht decodiert werden kann oder die Deserialisierung in TFHE-Typen fehlschlägt. Rückgabe als String im Body.

GET /auswerten Wertet die gespeicherten Gebote homomorph aus.

- Response (200 OK):
 - status (String): Meta-Information über die Anzahl der ausgewerteten Gebote.
 - encrypted_result (String): Base64-codierter tfhe::FheUint32 Payload des höchsten Gebotes.
- Fehler (400 Bad Request):
 - Tritt auf, wenn die interne Gebotsliste leer ist.

3.4.3 Trust- und Threat-Model

	Server klar	Server verschlüsselt	Nur Client
Bieter-Name (bidder_name)	X		
Gebotshöhe (encrypted_amount)		X	
Max-Gebot (encrypted_result)		X	
Server-Key	X		
Client-Key			X

Metadaten-Analyse: Ein böartiger Server-Operator kann die exakte Anzahl der Gebote, die Identitäten (Namen) der Teilnehmer und die genauen Zeitpunkte der Gebotsabgaben einsehen. Da FHE-Chiffre für denselben Datentyp statische Größen aufweisen, sind Rückschlüsse auf die Höhe des Gebots durch Längenanalysen ausgeschlossen. Der Server-Operator könnte Traffic-Analysen fahren oder die Auswertung blockieren (Denial of Service).

Restvertrauen & Garantien: Es muss dem Server vertraut werden, dass er den Algorithmus korrekt anwendet. Ein manipulierender Server könnte willkürlich legitime Gebote aus der Liste entfernen (Zensur) oder das Resultat fälschen, indem er einfach das Chiffre eines bevorzugten Bieters als Ergebnis zurückschickt, ohne die homomorphe Auswertung jemals durchgeführt zu haben. Schutzversprechen: Der Server lernt unter keinen Umständen die Höhe der eingereichten Gebote und auch nicht den Gewinner-Wert.

3.4.4 FHE-Designentscheidungen

- Typen-Wahl: Für die Gebotshöhen wird `FheUInt32` verwendet. 32-Bit Unsigned Integer erlauben Gebote bis zu knapp 4,3 Milliarden, was für reale Auktionsszenarien absolut ausreichend ist. Der Typ ist deutlich performanter auszuwerten als `FheUInt64`.
- Operationen: Zur Ermittlung des Höchstgebots werden ausschließlich der numerische Vergleich `.gt()` (Greater Than) und das Multiplexing `.select()` verwendet. Mathematische Operationen wie Addition oder Multiplikation sind hier nicht erforderlich.
- Verworfenen Varianten: Die Sortierung der gesamten Liste wurde verworfen, da eine vollständige Sortierung in FHE aufgrund von datenunabhängigen Branches Komplexität aufbaut und nicht nötig ist. Stattdessen implementiert der Code ein lineares Scannen (Max-Suche), das den aktuellen Höchstwert überschreibt.

3.4.5 Komplexität der eigenen Algorithmen

Die Funktion `evaluate_encrypted_auction` iteriert über die Liste der eingegangenen Gebote. Sei n die Anzahl der abgegebenen Gebote (wobei $n \geq 1$).

Der Algorithmus überspringt das erste Element und iteriert exakt $n - 1$ mal. Pro Iteration werden exakt zwei FHE-Operationen ausgeführt:

- Ein Vergleich (Greater Than): `gt()`
- Eine Auswahl (Mux): `select()`

Die asymptotische Laufzeit im Hinblick auf eigene FHE-Operationen beträgt damit exakt:

Komplexität = $O(n)$ Der Platzbedarf während der Auswertung (zusätzlich zu den eingelesenen Chiffren) ist $O(1)$, da stets nur eine einzige Variable (`maximales_gebot`) für den Zwischenstand genutzt wird.

3.4.6 Performance-Messung

Die Performancemessung fand auf einem Netcup RS 1000 G9.5 statt, dem 2 vCores und 4 GB RAM zugewiesen wurden. Als Testdatensatz dienten Serienschlüsselungen über ein automatisiertes Benchmark-Skript.

- Latenzen: Bei 10 sequentiellen Geboten beträgt die Auswertungs-Latenz (p50) auf dem Endpoint `/auswerten` ca. 2,83 Sekunden. Bei 50 Geboten steigt p95 auf ca. 14,15 Sekunden, was der streng linearen Skalierung ($O(n)$) der homomorphen Schleife entspricht.
- Speicherbedarf: Während der Auswertung von 50 Bids werden ca. 120 MB RAM verbraucht, was primär auf das einmalige Laden des großen `CompressedServerKey` in den Arbeitsspeicher zurückzuführen ist.
- Durchsatzgrenzen: Wenn parallel mehrere `GET /auswerten`-Requests eintreffen (ab ca. 1 bis 2 Requests / Sekunde), gerät der Server ans CPU-Limit voreingestellter Threadpools. Da der globale Zustand über ein `state.lock()` (Mutex) während der gesamten FHE-Berechnung blockiert wird, entsteht bei parallelen Zugriffen ein massiver

Verarbeitungstau, der Timeouts (>30s) bei den Clients auslöst. Die Gebotsannahme (POST /gebot) ist hingegen nicht durch FHE-Operationen gebunden (die Ciphertexte werden lediglich als Bytes entgegengenommen und im RAM abgelegt) und skaliert im Bereich von Hunderten Requests pro Sekunde mühelos.

3.4.7 Limitationen

1. Keine Auflösung des Gewinners: Das System liefert ausschließlich den Betrag des höchsten Gebotes als Chiffre zurück. Der Server kann fachlich nicht feststellen, hinter welchem bidder_name dieser Betrag steckt. Dem Bieter ist zwar das Max-Gebot nach Entschlüsselung bekannt; es existiert abseits von Off-Chain-Verifikationen jedoch aktuell kein kryptographischer Nachweis, der den Gewinner-Betrag mit dem einreichenden Namen verknüpft.
2. Single-Key Assumption (Multi-Key FHE fehlt): Die aktuelle Implementierung unterstellt im Code (`let real_sk_bytes = &liste[0].server_key_bytes;`), dass alle Bieter mit demselben gemeinsamen ClientKey verschlüsselt haben. Ein echtes verteiltes Trust-System, in dem jeder Bieter einen eigenen unabhängigen Key besitzt (Multi-Key FHE), ist nicht implementiert.
3. Flüchtiger Speicherzustand: Bids werden im Arbeitsspeicher über `static BIDS: Mutex<Vec<Bid>>` vorgehalten. Bei Container- oder Anwendungsneustarts ist die gesamte Auktion unwiederbringlich verloren.
4. Fehlende Zugriffskontrolle: Es gibt derzeit keinen Authentifizierungsmechanismus. Jeder Client kann beliebig viele Gebote übermitteln, und jeder kann die Endauswertung triggern. Spam- und DoS-Absicherung fehlt auf Service-Ebene.

3.5 Encrypted-Statistics-Service

3.5.1 Funktionsbeschreibung

UC5 berechnet statistische Kennzahlen (Summe, Anzahl, Minimum, Maximum, Durchschnitt, Median) über eine Ganzzahlen-Liste, ohne dass der Server die Eingabewerte oder Ergebnisse jemals im Klartext sieht. Alle Berechnungen laufen vollständig auf verschlüsselten Daten.

Der `ServerKey` (~80 MB) wird einmalig via `POST /session` hochgeladen und einer `Session-UUID` zugewiesen. Alle weiteren Requests (`POST /`) senden nur die `UUID` — kein Key-Overhead pro Request.

Akteure:

- **Client** (Browser, Angular-Frontend): Generiert das TFHE-Schlüsselpaar, verschlüsselt die Eingabewerte mit dem `ClientKey` und lädt den `ServerKey` einmalig via `POST /session` hoch. Der `ClientKey` verlässt den Browser nie — nur der Client kann die Ergebnisse entschlüsseln.
- **Server** (Axum/Rust-Service): Empfängt den `ServerKey` einmalig, dekomprimiert ihn und speichert ihn pro Session. Alle weiteren Requests nutzen die gecachte Engine. Der Server sieht zu keinem Zeitpunkt Eingabewerte oder Ergebnisse im Klartext.

Ablauf:

1. Client generiert TFHE-Schlüsselpaar (`ClientKey` + `ServerKey`).
2. `POST /session \{ server_key \}` → Server dekomprimiert, speichert, vergibt `Session-UUID`.
3. Client wählt Bitbreite anhand von min/max der Eingabe (`Int8` / `Int16` / `Int32`).
4. Client verschlüsselt Werte und base64-kodiert sie.
5. `POST / \{ session_id, encrypted_list, bit_width \}` → Server lädt die Session per `UUID` und berechnet alle Statistiken verschlüsselt.
6. Client entschlüsselt Ergebnisse mit `ClientKey`.

3.5.2 OpenAPI-Schnittstelle

POST /session: Lädt den `ServerKey` einmalig hoch und gibt eine `Session-UUID` zurück. Alle weiteren Requests nutzen nur noch die `UUID`.

Request-Schema:

```
{
  "server_key": "<Base64-String>"
}
```

Feld	Typ	Beschreibung
server_key	string	Base64(bincode(CompressedServerKey)) — vom Client generiert, enthält kein Geheimnis.

Response-Schema (200 OK):

```
{
  "session_id": "550e8400-e29b-41d4-a716-446655440000"
}
```

POST /: Berechnet alle Statistiken für eine verschlüsselte Ganzzahlen-Liste.

Request-Schema:

```
{
  "session_id": "550e8400-e29b-41d4-a716-446655440000",
  "encrypted_list": ["<Base64-String>", "..."],
  "bit_width": 8
}
```

Feld	Typ	Beschreibung
session_id	string	UUID aus POST /session.
encrypted_list	string[]	Jedes Element: Base64(bincode(FheIntN)), wobei N = bit_width. Mindestens 1 Element.
bit_width	number	Muss 8, 16 oder 32 sein. Wird vom Client automatisch aus dem Wertebereich der Eingabe gewählt.

Response-Schema (200 OK):

```
{
  "sum": "<Base64-String>",
  "count": 42,
  "min": "<Base64-String>",
  "max": "<Base64-String>",
  "average": "<Base64-String>",
  "median": "<Base64-String>",
  "bit_width": 8
}
```

Feld	Typ	FHE-Typ (je nach bit_width)
sum	string	Base64(bincode(FheInt16/32/64)) - eine Stufe breiter als Eingabe
count	number	Klartextzahl - dem Server schon aus dem Request bekannt
min	string	Base64(bincode(FheInt8/16/32)) - gleiche Breite wie Eingabe
max	string	Base64(bincode(FheInt8/16/32)) - gleiche Breite wie Eingabe
average	string	Base64(bincode(FheInt16/32/64)) - eine Stufe breiter als Eingabe
median	string	Base64(bincode(FheInt8/16/32)) - gleiche Breite wie Eingabe
bit_width	number	Tatsächlich verwendete Bitbreite: 8, 16 oder 32

Fehlerstatus:

Status	Bedeutung
400 Bad Request	Leere Liste, ungültiger Base64, falscher Ciphertext-Typ, ungültige bit_width
404 Not Found	Session nicht gefunden oder abgelaufen (Idle-Timeout 10 min)
500 Internal Server Error	Serialisierungsfehler beim Zusammenstellen der Response

Weitere Endpunkte:

Endpunkt	Methode	Beschreibung
/healthz	GET	Liveness-Probe (Kubernetes)
/readyz	GET	Readiness-Probe (Kubernetes)
/version	GET	Service-Version als JSON
/metrics	GET	Prometheus-Metriken
/docs	GET	Swagger UI (OpenAPI-Dokumentation)
/openapi.json	GET	OpenAPI-Spec als JSON

3.5.3 Trust- und Threat-Model

Was am Server bekannt ist:

Datum	am Server klar	am Server verschlüsselt	nur am Client
Eingabewerte (die eigentlichen Zahlen)	-	FheInt8/16/32	Klartext vor Verschlüsselung
Anzahl der Elemente (n)	(Array-Länge im Request)	-	-
Wertebereich-Klasse	(über bit_width: Int8 → Werte in [-128, 127])	-	-
Summe	-	FheInt16/32/64	nach Entschlüsselung
Minimum	-	FheInt8/16/32	nach Entschlüsselung
Maximum	-	FheInt8/16/32	nach Entschlüsselung
Durchschnitt	-	FheInt16/32/64	nach Entschlüsselung
Median	-	FheInt8/16/32	nach Entschlüsselung
ServerKey	(einmalig via POST /session)	-	-
ClientKey	-	-	verlässt den Browser nie
Anfragezeitpunkt	(HTTP-Timestamp)	-	-
Payload-Größe	(HTTP-Header)	-	-

Analyse: Beobachtbare Metadaten: TFHE schützt ausschließlich den Inhalt der Eingabewerte und Ergebnisse. Für den Server bleiben weiterhin verschiedene Metadaten sichtbar:

- Anzahl n ist vollständig sichtbar. Ein Angreifer kann daraus schließen, wie viele Werte analysiert werden (z.B. „der Client hat genau 3 Werte geschickt“ → möglicherweise 3 Messwerte eines Sensors).
- bit_width verrät den Wertebereich: bit_width=8 bedeutet, alle Werte liegen in [-128, 127]. Bei kleinen Listen und bekanntem Kontext könnten Werte erraten werden.

- Request-Timing hängt von `n` und `bit_width` ab, nicht von den konkreten Werten — kein datenwertabhängiges Timing-Leak.
- Payload-Größe lässt sich direkt aus `n` und `bit_width` berechnen (alle FHE-Ciphertexte haben konstante Größe). Kein zusätzlicher Informationsgewinn.

Restvertrauen in den Server: Der Server kann die Eingabewerte nicht entschlüsseln, muss aber trotzdem korrekt handeln. Der Use Case vertraut darauf, dass der Server:

- alle Statistiken korrekt berechnet und keine manipulierten Ergebnisse zurückgibt,
- die korrekten verschlüsselten Ergebnisse zurücksendet und sie nicht durch manipulierte Ciphertexte ersetzt,
- den ServerKey nicht persistiert oder weitergibt,
- Sessions voneinander trennt.

Annahmen außerhalb von TFHE:

- TLS zwischen Client und Server (kein Mitlesen im Transit).
- Das Angular-Frontend und der Browser sind nicht kompromittiert (ClientKey liegt im WASM-Speicher).
- TFHE-rs wird als kryptographisch korrekt implementierte Black Box betrachtet.
- Es gibt keine Authentifizierung am Endpunkt: jeder kann Requests an `POST /session` und `POST /` schicken.

Schutzversprechen: Durch den Einsatz von TFHE wird garantiert:

- Der Server kann die Eingabewerte nicht im Klartext lesen.
- Der Server kann die berechneten Statistiken nicht im Klartext lesen.
- Alle Berechnungen werden ausschließlich auf verschlüsselten Daten durchgeführt.

Nicht garantiert werden:

- Schutz vor einem Server, der korrekte Berechnungen durch manipulierte Ergebnisse ersetzt.
- Vertraulichkeit von Metadaten (Listenlänge `n`, Wertebereich über `bit_width`, Request-Timing).
- Authentizität der Ciphertexte (kein ZKP, keine Client-Authentifizierung).

„Der Server kennt die Eingabewerte nicht. Er sieht nur Ciphertexte, addiert und vergleicht sie ohne je einen Klartext zu sehen, und gibt alle Statistiken verschlüsselt zurück. Nur der Client kann die Ergebnisse mit seinem ClientKey entschlüsseln.“

3.5.4 FHE-Designentscheidungen

Verwendete TFHE-rs-Typen:

Eingabe-Bitbreite	Eingabe-Typ	Summe/Avg-Typ	Begründung
8	FheInt8	FheInt16	Overflow-Schutz: $n * 127$ muss in den Output-Typ passen
16	FheInt16	FheInt32	Gleiche Logik, nächste Ebene
32	FheInt32	FheInt64	Int64 deckt alle realistischen Summen ab

Auto-Bitbreiten-Wahl: Der Client bestimmt anhand von `min` und `max` der Eingabe die kleinste ausreichende Bitbreite:

- Int8 wenn $\min \geq -128$ und $\max \leq 127$
- Int16 wenn $\min \geq -32.768$ und $\max \leq 32.767$
- Int32 sonst

Der Server benötigt `bit_width` zwingend, um den richtigen FHE-Typ für die Deserialisierung zu wählen - FheInt8, FheInt16 und FheInt32 sind binär inkompatibel. Das Feld ist daher keine optionale Optimierung, sondern technisch notwendig.

Kleinere Bitbreiten reduzieren die Berechnungszeit deutlich, da die TFHE-Kosten mit der Bitbreite skalieren.

Verwendete homomorphe Operationen:

Operation	Verwendet für	Kosten
CastInto	Up-Cast InputType $\rightarrow$ WiderOutputType vor Summation	günstig
Add	Summation (parallel via rayon)	moderat
FheOrd (lt/gt)	Vergleich in min/max und <code>compare_and_swap</code>	teuer (Bootstrapping)
IfThenElse auf Fhe-Bool	Wählt das Ergebnis homomorph aus, ohne den Wert zu kennen	moderat
Division durch Klartextskalar	Durchschnitt: $\text{sum} / (n \text{ as } i16/i32/i64)$	deutlich günstiger als FHE-Division

Verworfenen Alternativen:

- Float (f32/f64): Semantisch passend für Durchschnitt, aber TFHE-rs bietet keine Float-Typen.
- Vollständig homomorphe Division: TFHE-rs hat keine generische `Div<FheInt>`-Implementierung. Division durch einen Klartextwert ist hier ausreichend, weil die Listenlänge dem Server ohnehin bekannt ist.
- Naiver sequentieller Sortieralgorithmus für Median: Bubblesort wäre $O(n^2)$ Komparatoren und vollständig sequentiell — auf FHE-Niveau unakzeptabel. Das Batchernetzwerk ist datenunabhängig (keine Branches auf Plaintext-Vergleichsergebnissen) und hat $O(\log^2 n)$ Tiefe.

- Partielles Sortiernetz (Median-optimiert): Ein Netz, das nur den Median-Index isoliert berechnet, würde weniger Komparatoren brauchen. Nicht umgesetzt, weil der Aufwand für das UC-Projekt nicht gerechtfertigt ist.
- Key pro Request (zustandsloses Design): Das ursprüngliche Design sendete den ~ 80 MB ServerKey mit jedem Request. Bei 15 Requests waren das $\sim 1,2$ GB Traffic und 50 % Fehlerrate unter Last, weil Nginx nach 60s abbricht. Ersetzt durch Session-Caching via `POST /session`.

3.5.5 Komplexität der eigenen Algorithmen

Parameter: n = Anzahl der Eingabeelemente. Jede einzelne FHE-Operation zählt als $O(1)$.

sum: Paralleles Reduce (rayon) auf n Elementen.

- Tiefe: $O(\log n)$ sequentielle Schritte (binärer Reduktionsbaum)
- Gesamtoperationen: $n-1$ Additionen
- Speicher: $O(n)$

count: $O(1)$ — nur `slice::len()`.

min / max: Identisch zu sum (Reduce mit Vergleich statt Addition).

- Tiefe: $O(\log n)$
- Gesamtoperationen: $n-1$ Vergleiche + $n-1$ `if_then_else`

average: $O(\log n)$ - identisch zu sum, plus eine $O(1)$ -Division durch Klartextskalar.

median (Batcher Odd-Even Mergesort): Das Batcher-Netzwerk für n Elemente hat (Herleitung: Knuth TAOCP Vol. 3, §5.3.4):

- Tiefe (Anzahl sequentieller Runden): $O(\log^2 n)$, exakt $\frac{1}{2} \cdot \log_2(n) \cdot (\log_2(n) + 1)$ für $n = 2^k$
- Gesamtanzahl Komparatoren: $O(n \log^2 n)$

Innerhalb einer Runde laufen alle Komparatoren parallel (rayon). Die Wandzeit entspricht der Netzwerk-Tiefe: $O(\log^2 n)$ sequentielle FHE-Runden.

Jeder Komparator besteht aus: $1 * \text{FheOrd-Vergleich} + 2 * \text{IfThenElse} = O(1)$ homomorphe Operationen.

Gesamtspeicher: $O(n)$ (der `partially_sorted`-Vektor als Arbeitspuffer).

3.5.6 Performance-Messung

Mess-Setup: k6 v2.0.0, `ConfigBuilder::default()`, Server: Netcup KVM, Last injiziert von lokaler Windows-Maschine über das Internet, Datum: 09.06.2026.

Test 1 — Baseline (1 VU, 5 Iterationen, alle Bitbreiten):

Konfiguration	p95 Latenz	Fehlerrate
n=5, bit_width=8	2,23 s	0 %
n=10, bit_width=8	4,46 s	0 %
n=10, bit_width=16	7,95 s	0 %
n=10, bit_width=32	16,16 s	0 %
Gesamt	—	0 % (20/20)

Gesendete Datenmenge: 113 MB — der ServerKey wird einmalig hochgeladen, alle weiteren Requests enthalten nur die verschlüsselten Werte. Ohne Session-Caching wären für dieselbe Anzahl Requests $\sim 1,2$ GB übertragen worden.

Fazit: Bei einem Client läuft der Service fehlerfrei über alle Bitbreiten. Die Latenz hängt ausschließlich von der FHE-Berechnung ab.

Test 2 — Stresstest (ramping bis 10 VUs, 6 Minuten):

Lastkurve: 60 s $\rightarrow$ 1 VU, 90 s $\rightarrow$ 3 VUs, 90 s $\rightarrow$ 6 VUs, 90 s $\rightarrow$ 10 VUs, 30 s $\rightarrow$ 0 VUs.

Metrik	Wert
Fehlerrate gesamt	52 % (77/149 Requests)
p95 Latenz (erfolgreiche Requests)	18,77 s
Fehler starten ab	~ 108 s (≈ 2 –3 parallele VUs)
Fehlertyp	HTTP 502 Bad Gateway (Nginx-Timeout nach 60 s)

Fazit: Ab ca. 2–3 parallelen Clients reicht die CPU nicht mehr aus, um alle Requests innerhalb des Nginx-Timeouts zu beantworten. Der Engpass ist rein CPU-seitig — nicht mehr der Netzwerk-Overhead wie im alten Design.

Bekannte Performance-Treiber:

- FheOrd-Vergleiche sind die teuersten Einzeloperationen (Bootstrapping-Kosten) — sie dominieren Median, min und max.
- Rayon-Parallelisierung innerhalb einer Batch-Runde skaliert mit den CPU-Kernen des Servers.
- Skalierung mit n: Verdopplung von n erhöht die Batch-Tiefe um ca. $2 \cdot \log_2 n$ Runden. Der Sprung von n=6 auf n=12 erhöht die Tiefe von ~ 9 auf ~ 16 Runden.
- Session-Caching: Der ServerKey wird einmalig pro Session dekomprimiert. Nicht genutzte Sessions werden nach 10 Minuten automatisch gelöscht.

Reproduzierbarkeit: Die k6-Skripte liegen unter `services/05-encrypted-statistics-service/src/Load-Tests`. Vor dem ersten Lauf muss ein Payload generiert werden:

```
# Payload generieren (einmalig, aus Repo-Root)
cargo run --release -p encrypted-statistics-service --bin gen_payload

# Tests ausführen (Windows PowerShell, aus Repo-Root)
cd services\05-encrypted-statistics-service\src\Load-Tests
k6 run baseline_load_test.js
k6 run stress_load_test.js
```

3.5.7 Limitationen

- Kein Float-Support: TFHE-rs unterstützt keine Float-Typen — alle Berechnungen sind auf ganzzahlige Typen beschränkt. Der Durchschnitt wird ganzzahlig ausgegeben — Nachkommastellen werden abgeschnitten ($[1, 2] \rightarrow 1$, nicht $1,5$).
- Sichtbare Metadaten: Die Listenlänge ist direkt aus dem Request ablesbar. `bit_width` verrät zusätzlich den Wertebereich der Eingabe. Beides ließe sich durch Padding oder eine feste Bitbreite verstecken — für diesen Use Case nicht umgesetzt, da es die Performance deutlich verschlechtern würde.
- Keine Eingabevalidierung: Der Server kann nicht prüfen, ob der Client korrekte FHE-Ciphertexte schickt — kein ZKP, keine Authentifizierung. Bei öffentlichem Zugang sind viele Anfragen möglich, die teure Rechenzeit binden.
- Listengröße: Bei $n > \sim 20$ mit `Int32` dauert die Berechnung mehrere Minuten. Der Service ist für kleine Listen ($n \leq \sim 15$) ausgelegt. Der Batch-Algorithmus sortiert außerdem die gesamte Liste, statt nur den Median zu isolieren — das ist mehr Arbeit als nötig, wurde aber nicht optimiert.
- Session-Lebensdauer: Sessions laufen nach 10 Minuten Inaktivität ab. Wer danach einen Request schickt, erhält 404 und muss den `ServerKey` erneut hochladen.

3.6 Encrypted-Genomics

Der folgende Abschnitt beschreibt die Implementierung des Use-Cases encrypted-genomics.

3.6.1 Funktionsbeschreibung

Der Use Case dient dem verschlüsselten Vergleich von DNA-Sequenzen gegen bekannte Riskmarker und gegen in Sessions gespeicherte verschlüsselte Sequenzen. Die Riskmarker sind global bekannt, Sessionsequenzen sind geheim. Rechnungen darf jeder Akteur anfordern, Entschlüsselungen kann gem. des Trust-Thread-Models nur der Owner einer Session.

DNA eine Folge von Nukleinbasen. Diese Basen sind für den Use-Case wie folgt kodiert worden:

Adenin	A	0
Thymin	T	1
Cytosin	C	2
Guanin	G	3

Die Rechendarstellung der Zahlen erfolgt als 8-Bit Integer. Das vereinfacht die Umwandlung in Tfh- und Handlerformate, die hier weitestgehend 8-Bit sind.

Implementiert wurden frei wählbare Verarbeitung mit der Hammingdistanz oder der Levenshteindistanz. Bioinformatische Besonderheiten wie verpflichtende Basenpaare oder RNA (Uracil statt Thymin) werden nicht berücksichtigt. Auch eine für wissenschaftliche Fragestellungen relevante Unterscheidung zwischen teilweisen Vorliegen von Sequenzen und Gewichtungen von Basensequenzen wird vorliegend nicht berücksichtigt. Es handelt sich um einfache Vergleiche der 4 Basen, bei der eine Gleichheit bei vollwertiger ungewichteter Gleichheit der Sequenzen oder Einzelbasen angenommen wird.

Akteure

- **Creator:** Client, der eine Session eröffnet. Er generiert sich alle drei Schlüssel und verfügt damit über Private-, Public- und Serverkey. Die Schlüsselgenerierung erfolgt auf Ebene des Clients (Browser). Der Creator kann Sequenzen beliebig verschlüsseln, Abgleiche verschlüsselter Sequenzen am Server anfragen und auch Rechenergebnisse mit dem Private-Key entschlüsseln.
- **Joined user:** Client, der einer Session beitrifft. Er verfügt nur über den Public-Key der Session. Mit diesem kann er eigene Sequenzen verschlüsseln. Die Verschlüsselten Sequenzen des Joined-Users werden wahlweise in die Riskmarker-Datenbank oder in die Session-Datenbank gelegt. Der Joined-User kann auch Abgleichsrechnungen am Server anfragen. Er erhält dann ein Ergebnis, das er nicht entschlüsseln kann. Schlüsselbedingt kann er keine eigene Rechnung durchführen.
- **Server:** Der Server übernimmt die Rechnungen für alle Clients. Er verfügt über den Server-Key und den Public-Key jeder Session. Da der Server mit einem globalen State arbeitet, koordiniert er alle Anfragen. Er führt eine FIFO aus, mit der die Schlüssel- und Befehlsausführung gesteuert wird. Er rechnet Gleichheitsvergleiche mit Hamming- und Levenshteindistanzen für bereits verschlüsselte (Session) und noch unverschlüsselte (Riskpattern) Sequenzen aus. Des Weiteren Speichert er alle Sequenzen, Public-Keys, Server-Keys und SessionIDs, um die Aufgaben und Schlüssel zu koordinieren:

Datenbank	Spalten	Zweck
genomics_sessions	id, public_key, server_key	Sessionlogik
risk_patterns	id, sequence,	Riskpatterns
sessionsequences	session_id, public_key, encrypted_bases	Sessionsequenzen

Lebenszyklus einer Session:

- **1. Session erstellen:** Creatorclient wählt Session erstellen aus. Lokal werden alle 3 Keys erzeugt und über POST\sessions an den Server versendet. Der Creator behält den Private-Key, Public- und Server-Key werden an den Server gesendet, der die beiden Keys speichert.
- **2. Weitere Clients:** Beliebige Clients können als Joined Clients mit der Anfrage GET\sessions der Session beitreten. In der Session erhalten sie den Public-Key der Session gem. der Datenbankzuordnung.
- **3. Sequenz verschlüsseln:** Creator und Teilnehmer kodieren ihre DNA lokal und verschlüsseln sie mit dem PublicKey. Die Sequenz bleibt hier noch lokal. Alternativ kann der Server eine klare Sequenz ueber POST /encrypt mit einem PublicKey verschlüsseln.
- **4. Riskmarker verwalten:** Ein Client kann Riskmarker als Klartext mit POST /patterns speichern. Sowohl in Front-, wie auch im Backend wird die Eingabe auf die gültigen Zeichen A, T, C, G kontrolliert. Der Riskmarker wird als Klartext in risk_patterns gespeichert.
- **5. Riskmarker-Vergleich:** Ein Client sendet verschlüsselte DNA plus session_id und optional pattern_id. Bei Hamming wird gegen ein ausgewaehltes Pattern oder alle Patterns der Datenbank per Sliding Window gerechnet. Jedes Sliding-Window entspricht hierbei der Patternsequenz. Ist das Pattern kleiner als das eingegebene Wort, so wird bis das Wort vollständig iteriert ist eine Hammingdistanz berechnet und anschließend ein Bitshift um 1 ausgeführt. Es gibt daher final Wort-Pattern viele Windows. Bei Levenshtein wird pro Pattern eine Distanz diagonal berechnet. Ist das Pattern größer als das Wort, wird der Riskmarkervergleich direkt abgebrochen, da der vom Entwickler gewählte Schwellenwert 100 Prozent übereinstimmung ist, also Levenshteindistanz 0 oder mindestens ein Window mit Hammingdistanz 0.
- **6. Sessionsequenzen speichern:** Jeder Sessionteilnehmer kann seine aktuell eingetragene DNA in sessionsequences speichern. Dort werden Session-ID, PublicKey, Ciphertexts und Laenge gespeichert. Wird der Button getätigt, wird die eingetragene Sequenz lokal verschlüsselt und verschickt. Sie wird in die Datenbank Sessionsequences abgelegt.
- **7. Sessionsequenz-Vergleich:** Der Client waehlt eine Session-ID aus der Sessionsequenz-Dropdown-Liste. Über einen Button kann er diese Liste aktualisieren. Seine aktuelle Sequenz wird mit dem PublicKey dieser Session verschlüsselt und gegen alle dort gespeicherten verschlüsselten Sequenzen verglichen. Hamming oder Levenshtein sind wieder frei wählbar. Hier treten Besonderheiten zum Riskmarker auf: bei Levenshtein wird ein einfacher Levenshteinvergleich durchgeführt. Bei Hamming wird hier immer die kleinere gegen die größere Sequenz geprüft. Ist in einem Window eine Hammingdistanz von 0 gegeben, liegt Gleichheit vor. Dies ist nach Entwickleransicht hier stimmig, da ein einfacher Gleichheitswert in eine der beiden Sequenzen schon eine gleiche Sequenz ohne

jede Bedeutung darstellen. Im Gegensatz zum Riskmarker, wo je nach Risikomuster und Krankheitsanfälligkeit ggf. 100 Prozent nötig sind, erscheint dies hier zielführend. Für Levenshtein wurde dies bewusst nicht umgesetzt, da die Rechnung damit extrem teuer wird. Auch eignet sich Levenshtein eher für zielgerichtete gewichtete Vergleiche mit oder ohne Windows, was den Rahmen der Aufgabe sprengen würde.

- **8. Auswertung:** Der Server gibt verschlüsselte Distanzen für Hamming oder Levenshtein zurück. Der Creator entschlüsselt diese lokal mit dem Private-Key. Joined-Clients sehen hier nur verschlüsselte Sequenzen.
- **9. Session verlassen:** `Leave session` löscht nur den lokalen Zustand im Frontend. Es gibt aktuell keinen Backend-Endpunkt zum Deaktivieren oder Löschen einer Session. Ein `rejoin` als Creator ist für niemanden möglich.

3.6.2 OpenAPI-Schnittstelle

Der Service startet auf <http://159.195.145.100/genomics>. Die OpenAPI-Dokumentation wird ueber `aide` erzeugt und mit `openapi-docs::attach` eingebunden. Je nach Deployment sind `/openapi.json` und `/docs` verfügbar. Es gibt keine Auth-Header in der Implementierung. Fehlerantworten sind einfache Textantworten mit HTTP-Statuscode. Folgende Antworten sind definiert:

Datenbank	Spalten
200	OK
400	Ungültige Eingabe einer Base oder Session
429	FIFO voll
500	Serialisierung- oder Lockfehler

3.6.3 Trust- und Threat-Model

Datum	Server	Creator	Joined
Session-ID	X	x	X
PublicKey	X	x	X
Server Key	X	x	
Private Key		x	
DNA Klartext	lokal	lokal	lokal
DNA-Verschlüsselt	x	X	X
Riskpatternn	x	x	x
Sessionsequenzen Rechnung	x		
Sessionsequenzen Ergebnis		x	
Hamming-Distanzen	x	x	x (encrypted)
Levenshtein-Distanzen	x	X	x (encrypted)
Sequenzlängen / Anzahl Basen		x	x
Windows Rechnung	x		
Windows Ergebnis	x	x	x
Anzahl Sequenzen Rechnung	x		
Anzahl Sequenzen Ergebnis	x	x	x

FIFO	x	x	x
Datenbank	x	per GET	per GET

Beobachtbare Metadaten Der Service schützt über TFHE den Inhalt der verschlüsselten DNA-Sequenzen und der berechneten Distanzen. Der Server sieht jedoch weiterhin Metadaten:

- Welche Session existiert und wie oft sie genutzt wird.
- Welche Riskmarker im Klartext existieren und welches Pattern abgefragt wird.
- Ob ein Einzelpattern oder All patterns abgefragt wird.
- Länge der verschlüsselten Vergleichssequenz, Länge gespeicherter Sessionsequenzen und daraus ableitbare Anzahl der Hamming-Windows.
- Anzahl gespeicherter Sessionsequenzen je Session.
- FIFO-Positionen, Job-Typen und ungefähre Laufzeiten.
- Ob ein Request wegen FIFO-Füllstand, Eingabelänge oder Pattern-Länge abgelehnt wurde.

Es lassen sich serverseitig durchaus Aktivitätsprofile aus Sequenzlängen, Nutzungsintensität einzelner Sessions und die verwendeten Riskmarker ableiten. Es list außerdem erkennbar, ob viele Anfragen auf dieselbe Session laufen oder ob bestimmte Riskmarker besonders häufig abgefragt werden. Ohne Private Key lassen sich aber keine konkreten Schlüsse für Server und auch Clients ziehen.

Restvertrauen in den Server Der Server kann nicht entschlüsseln, muss aber korrekt handeln. Der Use Case vertraut darauf, dass der Server:

- die richtigen Session-Keys zur richtigen Session lädt,
- Riskmarker und Sessionsequenzen vollständig und unverfälscht aus der Datenbank liest,
- keine Patterns austauscht oder Ergebnisse unterschlägt,
- FIFO-Jobs fair in Reihenfolge abarbeitet,
- den ServerKey nur für die vorgesehene homomorphe Berechnung verwendet,
- verschlüsselte Ergebnisse unverändert an den Client zurückgibt.

TFHE reduziert das Vertrauen in den Server hinsichtlich Vertraulichkeit der DNA-Inhalte. Es ersetzt aber keine Integritätsbeweise, Authentifizierung und keine Verifikation, dass der Server tatsächlich genau den dokumentierten Code ausgeführt hat.

Annahmen außerhalb von FHE

- Die Transportverschlüsselung erfolgt im Deployment ueber TLS bzw. den vorgeschalteten Gateway.
- Das Angular-Frontend und `tfhe.js` führen Keygenerierung, Verschlüsselung und Entschlüsselung korrekt aus.
- TFHE-rs und TFHE-WASM werden als kryptographisch korrekte Black Boxes betrachtet.
- Der Private Key verlässt den Browser des Creators nicht.
- Die Datenbank ist für Verfügbarkeit und Integrität vertrauenswürdig genug.
- Es gibt keine starke Benutzer- oder Rollen-Authentifizierung im Genomics-Service.

Schutzversprechen Produktiv versprochen werden kann nur: Der Server verarbeitet DNA-Vergleichssequenzen und Sessionsequenzen als Ciphertexts und kann deren Klartext ohne ClientKey nicht lesen. Ebenfalls liegen die berechneten Hamming- und Levenshtein-Distanzen auf dem Server nur verschlüsselt vor.

Nicht versprochen wird: Schutz von Riskmarkern, Pattern-Auswahl, Session-IDs, Sequenzlängen, Zeitpunkten, FIFO-Metadaten, Datenbank-Metadaten oder Schutz gegen einen aktiv manipulierenden Server.

3.6.4 FHE-Designentscheidungen

Verwendete TFHE-rs-Typen

- `CompactPublicKey`: Wird verwendet, damit klare DNA-Werte effizient als kompakte Ciphertext-Liste verschlüsselt werden koennen. Der Server nutzt ihn insbesondere, um klare Riskmarker vor dem Vergleich zu verschlüsseln.
- `CompressedServerKey`: Wird vom Client erzeugt, base64-kodiert an den Server gesendet und serverseitig zu `ServerKey` dekomprimiert.
- `ServerKey`: Wird im Serverprozess gesetzt, damit homomorphe Operationen auf `FheUint8` ausgeführt werden können.
- `FheUint8`: Wird für verschlüsselte DNA-Basen, Hamming-Distanzen, Levenshtein-DP-Zellen und Ergebniswerte verwendet.

`FheUint8` reicht aus, weil DNA-Basen nur Werte von 0 bis 3 benoetigen und die Distanzwerte durch die Eingabelimits in den Bereich 0 bis 255 passen. Hamming erlaubt in der Implementierung maximal 255 Zeichen, Levenshtein maximal 122 Zeichen. Größere Typen erfordern entweder eine Erweiterung auf größere `FheUint`-Typen oder die Nutzung einer Overflowaddition, in der ein Overflow eine unklare Hammingdistanz + Overflow ausgibt. Aus dem Overflow kann man dann das Ergebnis NO MATCH ziehen. Darauf wurde aber verzichtet, da die Rechnung bewusst einfach und damit leicht parallelisierbar gemacht werden sollte.

Homomorphe Operationen Hamming:

- ne vergleicht zwei verschlüsselte oder verschlüsselt/klare Basen.
- `FheUint8::cast_from(FheBool)` wandelt Match/Mismatch in 0 oder 1.
- Homomorphe Addition summiert Mismatches im Window.

Levenshtein:

- ne berechnet die Substitutionskosten.
- Addition mit `1u8` modelliert Einfügung und Löschung. Eine Performanceverbesserung durch Nutzung von `trivial_encrypt(1u8)` konnte nicht verzeichnet werden.
- `lt` und `if_then_else` bilden `min` und `min3` fuer die DP-Rekurrenz.
- `FheUint8::encrypt_trivial` erzeugt öffentliche Startwerte für die DP-Ränder.

Algorithmische Varianten Der Service unterstützt zwei Arten von Pattern-Vergleichen:

- **Einzelvergleich gegen Riskmarker:** `/process` und `/process-levenshtein` laden ein klares Pattern aus der Datenbank. Hamming kann dabei verschlüsselte DNA direkt gegen klare Patternwerte vergleichen.
- **Datenbankvergleich gegen Riskmarker:** `/compare-db` und `/compare-db-levenshtein` verschlüsseln alle relevanten klaren Riskmarker erst mit dem `PublicKey` der Session und vergleichen dann Ciphertext gegen Ciphertext.
- **Sessionsequenzvergleich:** Beide Seiten liegen bereits verschlüsselt vor. Für Hamming wird bei unterschiedlich langen Sequenzen die längere Sequenz als Wort und die kürzere als Pattern genutzt.

Parallelisierung Der Server initialisiert Rayon mit der Anzahl verfügbarer CPU-Threads. Die rechenintensiven Handler laufen in `tokio::task::spawn_blocking`, damit der Async-Runtime-Thread nicht blockiert. Innerhalb der Berechnung werden Patterns, Sessionsequenzen, Serialisierung, Deserialisierung und Hamming-Windows parallelisiert.

Gleichzeitig gibt es eine globale FIFO. Dadurch nutzt jede einzelne Berechnung die Serverleistung, während weitere Jobs geordnet warten. Die FIFO-Kapazität ist aktuell 5 Jobs.

Verworfen oder bewusst vermiedene Varianten

- **Private Key an den Server senden:** Wurde bewusst nicht umgesetzt, weil dadurch der zentrale Schutz des Use Case verloren ginge.
- **Riskmarker nur klar vergleichen:** Für DB-Vergleiche werden Riskmarker serverseitig mit dem `PublicKey` verschlüsselt, damit die eigentliche Distanzberechnung homomorph auf Ciphertexts laeuft.

- **FheUint16/FheUint32 fuer Distanzen:** Für leichtere Parallelisierung und Optimierung
- lässt sich im Nachhinein leicht ändern.
- **Datenabhängiges Abkürzen bei Levenshtein:** Der Server kann wegen FHE nicht sinnvoll auf geheimen Zwischenwerten branchen. Die DP-Matrix wird deshalb systematisch berechnet.

3.6.5 Komplexität der eigenen Algorithmen

Funktion / Ablauf	Zeit	Speicher
DNA kodieren	$O(n)$	$O(n)$
Sequenz verschlüsseln	$O(n)$	$O(n)$
FIFO enqueue	$O(1)$	$O(1)$
FIFO snapshot	$O(q)$	$O(q)$
Sessions listen	$O(s)$	$O(s)$
Riskmarker listen	$O(p)$	$O(p)$
Riskmarker speichern	$O(m)$	$O(m)$
Sessionsequenz speichern	$O(n)$	$O(n)$
Hamming Einzelpattern	$O((n - m + 1) \cdot m)$	$O(n - m + 1)$
Hamming Riskmarker-DB	$O(\sum_i (n - m_i + 1) \cdot m_i)$	$O(\sum_i (n - m_i + 1))$
Hamming Sessionsequenzen	$O(\sum_i (n - m_i + 1) \cdot m_i)$	$O(\sum_i (n - m_i + 1))$
Levenshtein Einzelpattern	$O(n \cdot m)$	$O(n \cdot m)$
Levenshtein Riskmarker-DB	$O(\sum_i n \cdot m_i)$	$O(\max_i (n \cdot m_i) + p)$
Levenshtein Sessionsequenzen	$O(\sum_i n \cdot l_i)$	$O(\max_i (n \cdot l_i) + s)$

3.6.6 Performance-Messung

Die Performance- und Stresstests wurden gegen den deployed Genomics-Service auf dem Netcup-Server ausgeführt. Die Last wurde extern mittels k6 von einer lokalen Gentoo-Linux-Maschine über das Internet injiziert.

- Basis-URL: <http://159.195.145.100/genomics>
- Tool: k6

Es wurden zwei verwertbare Testszenarien untersucht:

1. **Normalbetrieb / Metadata Flow:** Analyse der Endpunkte GET /fifo, GET /sessions, GET /patterns und GET /sessionsequences.
2. **FIFO-/Session-Spike:** Plötzlicher Lastanstieg auf bis zu 250 parallele virtuelle Nutzer mit Fokus auf GET /fifo und GET /sessions.

3.6.7 Test 1: Normalbetrieb / Metadata Flow

Der Test ruft regelmässig FIFO-Status, Sessions, Risk Patterns und Session-Sequenzgruppen ab. Die Last wurde auf bis zu 30 parallele virtual users skaliert.

Metrik	/fifo	/sessions	/patterns	/sessionsequences
avg	40,53 ms	331,44 ms	29,61 ms	143,98 ms
min	2,32 ms	91,48 ms	11,38 ms	44,30 ms
p50	22,18 ms	227,92 ms	26,97 ms	94,17 ms
p90	39,86 ms	681,62 ms	43,37 ms	318,61 ms
p95	45,96 ms	844,57 ms	47,93 ms	383,22 ms
max	12,95 s	1,74 s	128,90 ms	771,80 ms

Metrik	Wert
HTTP Requests	5.872
Durchsatz	36,39 requests/s
Iterationen	1.492
Checks erfolgreich	5.872 / 5.872
Fehlerrate	0,00 %
HTTP p50	50,14 ms
HTTP p90	348,77 ms
HTTP p95	528,16 ms
HTTP max	12,95 s
Daten empfangen	4,3 GB
Daten gesendet	523 kB

Ergebnis Test 1: Es gab keine HTTP-Fehler. Auffaellig ist jedoch die deutlich hoehere Latenz von GET /sessions. Der p95-Wert von 844,57 ms ueberschreitet den gesetzten Threshold von 800 ms. Ursache ist vermutlich die grosse Antwortmenge der Sessionliste, da dort Public Keys mit uebertragen werden. Die uebrigen Endpunkte bleiben stabil im niedrigen Millisekundenbereich.

3.6.8 Test 2: FIFO-/Session-Spike

Es wurde ein ploetzlicher Lastanstieg auf bis zu 250 parallele virtual Users simuliert. Jeder user ruft wiederholt GET /fifo und GET /sessions ab.

Metrik	/fifo	/sessions
avg	52,86 ms	7,47 s
min	2,07 ms	70,54 ms
p50	41,22 ms	10,52 s
p90	62,15 ms	13,18 s
p95	260,22 ms	13,68 s
max	2,08 s	16,69 s

Fazit Test 2: Der Service bleibt funktional stabil. Es traten keine fehlgeschlagenen HTTP-Requests auf. Der FIFO-Endpunkt bleibt mit p95 = 260,22 ms vergleichsweise stabil. Der Sessions-Endpunkt skaliert dagegen schlecht unter hoher Parallelitaet und erreicht p95 = 13,68 s.

Metrik	Wert
HTTP Requests	2.574
Durchsatz	31,28 requests/s
Iterationen	1.287
Checks erfolgreich	2.574 / 2.574
Fehlerrate	0,00 %
HTTP p50	85,69 ms
HTTP p90	12,51 s
HTTP p95	13,18 s
HTTP max	16,69 s
Daten empfangen	2,5 GB
Daten gesendet	221 kB

3.6.9 Limitationen

- Der ClientKey existiert nur lokal beim Creator. Wenn der Creator die Seite verlässt, ist alles verloren.
- Joined Clients können Ergebnisse bewusst nicht entschlüsseln.
- Sessions werden aktuell nicht serverseitig geschlossen.
- Riskmarker müssen global und als Klartext gespeichert werden.
- Sessionsequenzen werden verschlüsselt gespeichert, aber Session, PublicKey und Anzahl der Sequenzen bleiben sichtbar.
- Hamming-Vergleiche sind auf 255 Zeichen begrenzt. Levenshtein-Vergleiche sind auf 122 Zeichen begrenzt.
- Bei Riskmarker-Einzelauswahl gibt es ein Zeichenlimit in Höhe von 255/122, da das Pattern nicht länger als die Clientsequenz sein darf.
- Levenshtein ist trotz Parallelisierung teuer, weil für jede DP-Zelle mehrere homomorphe Operationen nötig sind und viele Zellen diagonal voneinander abhängen.
- Die FIFO-Kapazität ist aktuell 5 Jobs. Ist die Liste voll, gibt der Server HTTP-Statuscode 429 zurück.
- Der Service setzt einen globalen ServerKey-Kontext und setzt Locks. Das verhindert parallele Berechnung verschiedener ServerKeys und passt zur FIFO-Architektur, begrenzt aber parallelen Multi-Session-Durchsatz.
- Es gibt keine kryptographischen Integritätsbeweise, dass der Server die angefragten Patterns, alle gespeicherten Sequenzen oder alle berechneten Distanzen korrekt verarbeitet hat.

3.7 Encrypted-Image-Processing

3.7.1 Funktionsbeschreibung

Die Aufgabe dieses Use-Cases ist, visuelle Operationen auf Bildern durchzuführen und dabei die Ressourcen eines Servers zu verwenden. Um Die Bilddaten vor dem Server geheim zu halten, werden die Bilddaten homomorph verschlüsselt und dem Server nur in dieser Form zur Verfügung gestellt. Der Server führt die gewünschten Operationen auf den verschlüsselten Bilddaten durch und sendet die Ergebnisse zurück an den Client, der sie entschlüsselt und anzeigt. Mithilfe eines Sessionprinzips können mehrere Rechenoperationen auf einem Bild durchgeführt werden, ohne dass der Client die Ergebnisse nach jeder Operation entschlüsseln muss. Hat der Client alle gewünschten Operationen durchgeführt, kann er die Ergebnisse entschlüsseln und anzeigen. Die Operationen, die auf den Bildern durchgeführt werden können, umfassen beispielsweise das Drehen und Spiegeln der Bilder, das Invertieren der Helligkeitswerte und das Blurren und Bloomen der Bilder wobei letzteres nicht vollständig umgesetzt werden konnte. Die Strategien und Gründe dazu werden in späteren Abschnitten erläutert.

Vorweg: Eine Session-ID existiert nicht, da die Session-Informationen direkt mit dem öffentlichen Schlüssel des Clients verknüpft sind. Der Server speichert die Session-Informationen und die verschlüsselten Bilddaten, solange die Session aktiv ist. Sobald der Client die Session beendet, werden die Session-Informationen und die verschlüsselten Bilddaten gelöscht, um die Privatsphäre des Clients zu schützen. Das öffnen mehrerer Sessions gleichzeitig wird nicht vom Service direkt unterstützt, da die Verarbeitung von Bildern bereits eine hohe Rechenlast auf dem Server verursacht.

Akteure:

- Client: Der Client erstellt eine Session, lädt die Bilder hoch, initiiert die gewünschten Operationen und entschlüsselt die Ergebnisse. Jeder Client kann über nur eine Session gleichzeitig verfügen und hat nur Zugriff auf die Bilder, die er selbst hochgeladen hat.
- Server: Der Server empfängt die verschlüsselten Bilder, führt die angeforderten Operationen durch und sendet die verschlüsselten Ergebnisse zurück an den Client. Der Server hat keinen Zugriff auf die unverschlüsselten Bilddaten und kann nur die verschlüsselten Daten verarbeiten. Er ist für die Verwaltung der Sessions und die Durchführung der Operationen verantwortlich.

Lebenszyklus einer Session:

1. Übersicht: Der Client lädt ein neues Bild hoch, dieses Bild wird zunächst nur im Frontend festgehalten, bis der Client den Editor startet.
2. Editor: Der Editor wandelt das Bild in ein Graustufenformat um, um die Verarbeitung zu vereinfachen. Der Editor zeigt das umgewandelte Bild an und zeigt dem Client die verfügbaren Operationen an.
3. Schlüsselpaar: Der Client generiert ein Schlüsselpaar.
4. Session: Der Client erstellt eine neue Session auf dem Server und übermittelt den öffentlichen Schlüssel sowie die Bilddaten, die in der Session verarbeitet werden sollen. Der Server speichert die Session-Informationen und die verschlüsselten Bilddaten.

5. Operationen: Der Client initiiert die gewünschten Operationen auf dem Bild, indem er Anfragen an den Server sendet. Der Server führt die angeforderten Operationen auf den verschlüsselten Bilddaten durch.
6. Finalisierung: Sobald der Client alle gewünschten Operationen durchgeführt hat, kann er die Ergebnisse entschlüsseln und anzeigen. Der Server löscht die Session-Informationen und die verschlüsselten Bilddaten, um die Privatsphäre des Clients zu schützen.
7. Wiederholung: Der Client kann jederzeit eine neue Session erstellen, um weitere Bilder zu verarbeiten oder die gleichen Bilder erneut zu bearbeiten.

Verhaltensdiagramm:

3.7.2 OpenAPI-Schnittstelle

Session-Endpunkte:

- **POST /session:** Erstellt eine neue Session, erwartet den `compressed_server_key: Vec<u8>`, die `image_data: Vec<Vec<u8>>`, die `width: u32` und die `height: u32` des Bildes.
- **DELETE /session:** Löscht die aktuelle Session und alle damit verbundenen Daten. Liefert die `image_data: Vec<Vec<u8>>` des bearbeiteten Bildes, sowie die `width: u32` und die `height: u32` des Bildes zurück.
- **GET /status:** Gibt Information darüber, ob zurzeit eine Session aktiv ist (`session_active: bool`).

Bild-Operationen: Die Bild-Operationen liefern keine zusätzlichen Daten an den Server und erhalten auch keine Daten zurück, da die Operationen direkt auf den verschlüsselten Bilddaten durchgeführt werden, die bereits in der Session gespeichert sind. Die Ergebnisse der Operationen werden erst am Ende der Session zurückgegeben, wenn der Client die Session löscht und die bearbeiteten Bilddaten entschlüsselt.

- **POST /per-pixel/invert:** Invertiert das Bild der aktuellen Session.
- **POST /per-pixel/white-threshold:** Alle Pixel über einem Helligkeitswert von 128 werden weiß.
- **POST /per-pixel/black-threshold:** Alle Pixel unter einem Helligkeitswert von 128 werden schwarz.
- **POST /rotate/90:** Dreht das Bild der aktuellen Session um 90 Grad.
- **POST /rotate/180:** Dreht das Bild der aktuellen Session um 180 Grad.
- **POST /rotate/270:** Dreht das Bild der aktuellen Session um 270 Grad.
- **POST /flip/vertical:** Kehrt das Bild der aktuellen Session vertikal um.
- **POST /flip/horizontal:** Kehrt das Bild der aktuellen Session horizontal um.
- **POST /effects/blur:** Wendet einen Unschärfe-Effekt auf das Bild der aktuellen Session an.
- **POST /effects/bloom:** Wendet einen Bloom-Effekt auf das Bild der aktuellen Session an.

3.7.3 Trust- und Threat-Model

	Server klar	Server verschlüsselt	Nur Client
ClientKey			X
ServerKey	X		
Session-Informationen	X		
Helligkeitswerte		X	
Bilddimensionen	X		
Vergleichs-/Grenzwerte	X		

Request- und Response-Schema:

Analyse beobachtbarer Metadaten: Es werden ausschließlich die Pixelwerte der Bilder verschlüsselt, während die Bilddimensionen (Breite und Höhe) unverschlüsselt bleiben. Diese Informationen können potenziell von einem Angreifer genutzt werden, um Rückschlüsse auf den Inhalt des Bildes zu ziehen, insbesondere wenn die Bilder eine charakteristische Größe haben. Es ist jedoch wichtig zu beachten, dass die Bilddimensionen allein nicht ausreichen, um den Inhalt des Bildes zu rekonstruieren oder sensible Informationen preiszugeben. Dennoch sollten diese Metadaten mit Vorsicht behandelt werden, da sie in Kombination mit anderen Informationen möglicherweise Rückschlüsse auf den Inhalt des Bildes ermöglichen könnten.

Auch der Sessionstatus ist unverschlüsselt und könnte von einem Angreifer beobachtet werden. Ein Angreifer könnte beispielsweise feststellen, wann eine Session aktiv ist und wie lange sie dauert, was potenziell Rückschlüsse auf die Aktivitäten des Clients zulassen könnte.

Vergleichs- und Grenzwerte stehen im Quellcode des Servers im Klartext zur Verfügung und werden erst dort mithilfe des ServerKeys verschlüsselt. Ein Angreifer könnte diese Werte einsehen und möglicherweise Rückschlüsse auf die Art der durchgeführten Operationen ziehen, insbesondere wenn die Werte charakteristisch für bestimmte Operationen sind.

Für den Server bleiben außerdem weiterhin verschiedene Metadaten sichtbar:

- Zeitpunkte und Häufigkeit der Anfragen
- IP-Adresse des anfragenden Clients
- Charakteristische Payload-Größe (80 MB), die auf TFHE-Schlüsselübertragung schließen lässt
- Anzahl der Anfragen pro IP

Restvertrauen in den Server:

3.7.4 FHE-Designentscheidungen

TFHE-rs-Typen: Da der Server Bilddaten verarbeitet, die in Graustufen vorliegen, benötigen die einzelnen Pixel eines Bildes nur einen Speicherplatz von 8-Bit und können keine negativen Werte enthalten. Daher werden die Bilddaten als Vektor von FheUInt8 (`Vec<FheUInt8>`) dargestellt, wobei jedes Byte einen Graustufenwert repräsentiert. Die Übertragung dieser Werte erfolgt mithilfe eines `Vec<Vec<u8>>`. Die Bilddimensionen (Breite und Höhe) werden als 32-Bit-Ganzzahlen (`u32`) dargestellt. Der öffentliche Schlüssel des Clients wird als komprimierter

Vektor von Bytes (`compressed_server_key: Vec<u8>`) dargestellt, um die Übertragung zu erleichtern.

Über die Verwendung von größeren Datentypen, wie beispielsweise `FheUint16` oder `FheUint32`, wurde ebenfalls nachgedacht, da diese komplexe Rechenoperationen ermöglichen, die ansonsten leicht zu Integer-Overflows führen können. Allerdings wurde letztendlich entschieden, die Bilddaten als `FheUint8` zu belassen, da die meisten Operationen auf den Pixelwerten selbst durchgeführt werden und die Verwendung von größeren Datentypen die Berechnungsdauer erheblich erhöhen würde, ohne einen signifikanten Nutzen zu bieten. Stattdessen wurden verschiedene Strategien implementiert, um die Berechnungsdauer zu reduzieren und gleichzeitig die Bildqualität zu erhalten, wie beispielsweise die Verwendung von gewichteten Summen anstelle von einfachen Additionen und Divisionen.

Operationen: Die Bildoperationen benötigen jeweils unterschiedliche mathematische Operationen, je nachdem, um was für eine Art von Operation es sich handelt. Transformierende Operationen (Spiegeln, Drehen) erfordern hauptsächlich die Umordnung der Pixelwerte, während per-pixel-Operationen (Invertieren, Schwellenwertanwendung) hauptsächlich arithmetische Operationen auf den Pixelwerten erfordern. Die Effekt-Operationen (Blurren, Bloomen) erfordern komplexere mathematische Operationen, die über einfache arithmetische Operationen hinausgehen. Dazu zählen Bitshifts, Vergleiche und gewichtete Summen von Pixelwerten, sowie mehrstufige Additionen.

Optimierungen: Die Berechnungsdauer auf Bildern steigt mit der Anzahl der Pixel stark an, da auf jedem einzelnen Pixel Operationen durchgeführt werden müssen. Um die Berechnungsdauer zu reduzieren, wurde Rayon verwendet, um die Berechnungen auf mehrere Threads zu verteilen. Die Per-Pixel-Operationen wurden so implementiert, dass sie auf jedem Pixel unabhängig voneinander ausgeführt werden können, was eine effiziente Parallelisierung ermöglicht. Die Effekt-Operationen wurden ebenfalls so implementiert, dass sie auf Blöcken von Pixeln arbeiten können, um die Berechnungsdauer zu reduzieren.

Die Effekt-Operationen benötigen Zugriff auf benachbarte Pixel, um die gewünschten Effekte zu erzielen. Um die Berechnungsdauer zu reduzieren, wurde der Zugriff auf benachbarte Pixel möglichst weit reduziert.

Blurring: Der Blurring-Effekt wurde mithilfe eines Box-Blur-Effekts implementiert, der die Helligkeitswerte eines Pixels mit den Helligkeitswerten seiner unmittelbaren und diagonalen Nachbarn mittelt. Um die Zugriffe auf benachbarte Pixel zu reduzieren, wurde die Berechnung in zwei Schritte aufgeteilt, in denen zunächst die horizontalen Nachbarn und anschließend die vertikalen Nachbarn berücksichtigt werden. Dadurch sind pro Pixel nur 6 Zugriffe (2×3) nötig, anstatt 9 Zugriffe (3×3) bei einem direkten Zugriff auf alle Nachbarn. Bei der Bildung des Ergebniswertes wurde anstatt einer Addition gefolgt von einer Division durch 9 eine gewichtete Summe gebildet, bei der die Werte der Nachbarpixel durch Bitshifts gewichtet und anschließend addiert wurden. Dadurch konnte die Berechnungsdauer weiter reduziert werden, da Bitshifts schneller als Divisionen sind. Zudem wird durch dieses Verfahren verhindert, dass die Werte der Pixel überlaufen, da die Werte der Nachbarpixel vor der Addition bereits reduziert werden.

Bei der Optimierung des Blurring-Effekts wurden verschiedene Ansätze ausprobiert, um die Berechnungsdauer weiter zu reduzieren. Dazu gehören verschiedene Ansätze zum Zusammenfassen der benachbarten Pixelwerte, sowie die Reduktion von Zugriffen auf benachbarte Pixel, indem diagonale Nachbarn nicht berücksichtigt werden. Weitere Ansätze wurden betrachtet aber nicht implementiert. Dazu gehörten die Verwendung von Look-Up-Tabellen, um die Ergebnisse von häufig vorkommenden Pixelwerten vorab zu berechnen, sowie die Verwendung von approximativen Algorithmen, die weniger genaue Ergebnisse liefern, aber schneller sind.

Letztendlich wurde jedoch entschieden, den Box-Blur-Effekt beizubehalten, da er eine gute Balance zwischen Bildqualität und Berechnungsdauer bietet.

Blooming: Der Blooming-Effekt ist in der aktuellen Implementierung nicht vollständig umgesetzt, da die Berechnungsdauer für diesen Effekt deutlich höher ist als für die anderen Effekte. Der Blooming-Effekt erfordert die Berechnung von gewichteten Summen von Pixelwerten über einen größeren Bereich von Nachbarpixeln, was zu einer erheblichen Erhöhung der Berechnungsdauer führt. Die aktuelle Implementation des Blooming-Effekts arbeitet klassischerweise mehrschrittig, wobei jeder Schritt per Pixel ausgeführt wird, um eine möglichst hohe Parallelisierung beizubehalten. Dazu wird zunächst eine Lightmap erstellt, die alle Pixelwerte unter einem Helligkeitswert von 220 auf 0 setzt. Diese Lightmap wird dann mit dem vorher beschriebenen Blurring-Effekt geblurred, um die Lichtquellen zu verbreiten. Anschließend wird die geblurte Lightmap mit dem Originalbild kombiniert, um den Blooming-Effekt zu erzielen. Das Ergebnis des Blurring-Effekts ist nicht stark genug, um den Blooming-Effekt zu erzielen, da in den Berechnungsschritten verschiedene Kompromisse eingegangen werden mussten, um die Berechnungsdauer zu reduzieren. Da die Berechnungsdauer selbst bei kleinen Bildern (32x32) schon bereits mehrere Minuten beträgt, wurde entschieden, den Blooming-Effekt nicht weiter zu optimieren, da er bereits in der aktuellen Form eine erhebliche Berechnungsdauer aufweist und die Optimierungsmöglichkeiten begrenzt sind.

Ein weiterer implementierter Ansatz des Blooming-Effekts war eine einschrittige Berechnung jedes Pixels, ähnlich wie beim Blurring-Effekt. Dabei wurden ebenfalls alle Nachbarwerte eines Pixels berücksichtigt und auf das original addiert, wenn deren Helligkeitswert über einer bestimmten Grenze lag. Dabei kam es jedoch zu unerwünschten Effekten, wie Integer-Overflows, die zu unbrauchbaren Ergebnissen führten.

3.7.5 Komplexität der eigenen Algorithmen

3.7.6 Performance-Messung

3.7.7 Limitationen

3.8 Encrypted-Leaderboard

3.8.1 Funktionsbeschreibung

3.8.2 OpenAPI-Schnittstelle

3.8.3 Trust- und Threat-Model

3.8.4 FHE-Designentscheidungen

3.8.5 Komplexität der eigenen Algorithmen

3.8.6 Performance-Messung

3.8.7 Limitationen

3.9 Encrypted-Program-Execution

3.9.1 Funktionsbeschreibung

3.9.2 OpenAPI-Schnittstelle

3.9.3 Trust- und Threat-Model

3.9.4 FHE-Designentscheidungen

3.9.5 Komplexität der eigenen Algorithmen

3.9.6 Performance-Messung

3.9.7 Limitationen